



UNIVERSIDAD INDOAMÉRICA

FACULTAD DE INGENIERÍAS

INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN

TEMA:

DESARROLLO DE UN PROTOTIPO DE ASISTENTE VIRTUAL INTELIGENTE CON INTERFAZ DE AVATAR 3D Y VISIÓN ARTIFICIAL PARA LA DIFUSIÓN DE INFORMACIÓN ACADÉMICA DE LOS ESTUDIANTES DE UNA INSTITUCIÓN EDUCATIVA

Trabajo de Titulación modalidad Trabajo de Integración Curricular

Autor

Paulo Emilio Espinoza Jiménez

Tutor

Ing. Christian Eduardo Iza Llumiguisín

QUITO – ECUADOR

2026

AUTORIZACIÓN DE REPOSITORIO DIGITAL

Yo, Paulo Emilio Espinoza Jiménez, declaro ser autor del Trabajo de Titulación con el nombre “Desarrollo de un prototipo de asistente virtual inteligente con interfaz de avatar 3D y visión artificial para la difusión de información académica de los estudiantes de una institución educativa”, como requisito para optar al grado de Ingeniero en Tecnologías de la Información y autorizo al Sistema de Bibliotecas de la Universidad Tecnológica Indoamérica para que, con fines netamente académicos, divulgue esta obra a través del Repositorio Digital Institucional (RDI-UTI).

Los usuarios del RDI-UTI podrán consultar el contenido de este trabajo en las redes de información del país y del exterior, con las cuales la Universidad tenga convenios. La Universidad Tecnológica Indoamérica no se hace responsable por el plagio o copia del contenido parcial o total de este trabajo.

Del mismo modo, acepto que los Derechos de Autor, Morales y Patrimoniales sobre esta obra serán compartidos entre mi persona y la Universidad Tecnológica Indoamérica, y que no tramitaré la publicación de este trabajo en ningún otro medio sin autorización expresa de la misma. En caso de que exista el potencial de generación de beneficios económicos o patentes, producto de este trabajo, acepto que se deberán firmar convenios específicos adicionales donde se acuerden los términos de adjudicación de dichos beneficios.

Para constancia de esta autorización, en Quito, Ecuador, a los xx días del mes de xx de 2026, firmo conforme:

Autor: Paulo Emilio Espinoza Jiménez

Firma:

Número de Cédula: 1722558374

Dirección: Pichincha, Quito, El Inca, Kenedy

Correo Electrónico: emil.200409@gmail.com

Teléfono: 0986639128

APROBACIÓN DEL TUTOR

En mi calidad de Tutor del Trabajo de Titulación “DESARROLLO DE UN PROTOTIPO DE ASISTENTE VIRTUAL INTELIGENTE CON INTERFAZ DE AVATAR 3D Y VISIÓN ARTIFICIAL PARA LA DIFUSIÓN DE INFORMACIÓN ACADÉMICA DE LOS ESTUDIANTES DE UNA INSTITUCIÓN EDUCATIVA”, presentado por Paulo Emilio Espinoza Jiménez, para optar por el Título de Ingeniero en Tecnologías de la Información.

CERTIFICO

Que dicho Trabajo de Titulación ha sido revisado en todas sus partes y considero que reúne los requisitos y méritos suficientes para ser sometido a la presentación pública y evaluación por parte del Tribunal revisor que se designe.

Quito, Ecuador, 21 de agosto de 2026

Ing. Christian Eduardo Iza Llumiguísín

DECLARACIÓN DE AUTENTICIDAD

Yo, Paulo Emilio Espinoza Jiménez, declaro que los contenidos y los resultados obtenidos en el presente Trabajo de Titulación “Desarrollo de un prototipo de asistente virtual inteligente con interfaz de avatar 3D y visión artificial para la difusión de información académica de los estudiantes de una institución educativa”, como requerimiento previo para la obtención del Título de Ingeniero en Tecnologías de la Información, son absolutamente originales, auténticos y personales y de exclusiva responsabilidad legal y académica del autor.

Para constancia de esta declaración, firmo conforme:

Quito, Ecuador, 21 de agosto de 2026

Paulo Emilio Espinoza Jiménez
(Número de cédula)

APROBACIÓN DE LECTORES

El Trabajo de Titulación ha sido revisado, aprobado y autorizada su impresión y empastado sobre el tema “DESARROLLO DE UN PROTOTIPO DE ASISTENTE VIRTUAL INTELIGENTE CON INTERFAZ DE AVATAR 3D Y VISIÓN ARTIFICIAL PARA LA DIFUSIÓN DE INFORMACIÓN ACADÉMICA DE LOS ESTUDIANTES DE UNA INSTITUCIÓN EDUCATIVA”, presentado por Paulo Emilio Espinoza Jiménez, previo a la obtención del Título de Ingeniero en Tecnologías de la Información, y reúne los requisitos de fondo y forma para su sustentación.

Quito, Ecuador, 21 de agosto de 2026

Blanca Liliana Topón Visarrea
MIEMBRO DE TRIBUNAL

Juan Francisco Pabón Alajo
MIEMBRO DE TRIBUNAL

DEDICATORIA

*Quisiera dedicar este proyecto de titulación a mi familia,
especialmente a mi mamá y a mi abuelita.
Gracias a ellas todo esto fue posible. Estaré infinitamente
agradecido por tener a personas tan increíbles y buenas en mi vida;
siempre serán las mejores. Les dedico este logro como muestra de
gratitud por su apoyo incondicional, sus ánimos y todo el inmenso
cariño que me han brindado durante mi etapa universitaria.
De igual manera, dedico este trabajo a mis profesores, quienes
siempre se preocuparon por nosotros, nos impulsaron a mejorar y
tuvieron mucha paciencia para que lográramos los resultados
esperados.
Su valiosa orientación e invaluable apoyo hicieron posible el
desarrollo de esta investigación.*

Paulo Emilio Espinoza Jiménez

AGRADECIMIENTO

Expreso mi más sincero agradecimiento a la Universidad Tecnológica Indoamérica, a la Facultad de Ingenierías, y a mis compañeros de curso.

Gracias por la formación académica brindada y por todo el conocimiento que hemos construido a lo largo de estos años, descubriendo muchas cosas nuevas juntos y ayudándonos mutuamente a superar cada desafío.

De manera especial, extendiendo mi gratitud al Ing. Christian Iza y al Ing. Andrés Rubio, por su dedicación inquebrantable. Todos los conocimientos impartidos, su excelente criterio técnico y sus invaluable enseñanzas compartidas fueron pilares fundamentales para hacer realidad este proyecto.

Paulo Emilio Espinoza Jiménez

Índice de Contenidos

CAPÍTULO I:	Introducción	18
1.1	Contextualización	18
1.2	Estado del Arte	20
1.2.1	Diagnóstico del Sistema de Información Institucional en la Universidad Tecnológica Indoamérica	21
1.2.2	Evolución Tecnológica: Asistentes Virtuales, Avatares 3D y Visión Artificial	23
1.2.3	Adopción de Inteligencia Artificial en Universidades del Ecuador	24
1.2.4	Análisis Comparativo de Soluciones y Proyectos Similares	25
1.3	Planteamiento del Problema	31
1.4	Justificación	31
1.4.1	Utilidad	32
1.4.2	Beneficiarios	32
1.4.3	Factibilidad e Impacto Potencial	32
1.5	Objetivos	34
1.5.1	Objetivo General	34
1.5.2	Objetivos Específicos	34
1.6	Alcance del Proyecto	34
1.7	Fundamentación Teórica	35
1.7.1	Inteligencia Artificial y Procesamiento de Lenguaje Natural (PLN)	36
1.7.2	Visión Artificial e Interacción Visual no Biométrica	36
1.7.3	Agentes Conversacionales Encarnados (ECAs) y Avatares 3D	37
1.7.4	Arquitectura de Software para Asistentes Virtuales Multimodales	37

CAPÍTULO II:	Metodología	38
2.1	Diagnóstico de la Situación Actual	38
2.2	Área de Estudio	42
2.3	Metodología de Desarrollo o Implementación	42
2.4	Técnicas e Instrumentos de Recolección de Información	44
2.4.1	Técnicas para la Fase de Diagnóstico y Desarrollo	44
2.4.2	Técnicas para la Fase de Evaluación y Validación	44
2.5	Requerimientos del Proyecto	45
2.5.1	Requerimientos Funcionales (RF)	46
2.5.2	Requerimientos No Funcionales (RNF)	49
2.6	Diseño de la Solución	54
2.6.1	Capa de Percepción y Captura (Frontend Físico)	58
2.6.2	Capa de Procesamiento Cognitivo (Motor de IA)	58
2.6.3	Capa de Renderizado e Interacción (Frontend Gráfico)	58
2.7	Justificación Técnica	59
2.7.1	Despliegue en Servidor Local (Edge/Local Computing)	59
2.7.2	Implementación de la Arquitectura RAG frente a Fine-Tuning	60
2.7.3	Visión Artificial mediante Modelos Ligeros	60
2.7.4	Plataformas de Avatar Estandarizadas	60
CAPÍTULO III:	Implementación, Pruebas y Resultados	61
3.1	Descripción de la Solución	61
3.2	Proceso de Implementación	64
3.2.1	Implementación de Visión Artificial Ligera y Web-Sockets	64
3.2.2	Procesamiento de Documentos y Motor RAG Multilingüe	65
3.2.3	Procesamiento de Voz Asíncrono (Whisper y ElevenLabs)	66
3.2.4	Interfaz Dual y Renderizado WebGL	66
3.3	Pruebas y Validación	67
3.3.1	Pruebas Técnicas de los Modelos (IA)	67
3.3.2	Pruebas de Concurrencia	69
3.3.3	Protocolo de Pruebas con Usuarios	69
3.3.4	Evaluación Funcional de Visión Artificial	70

3.3.5	Matriz de Validación de Requerimientos	71
3.4	Resultados	72
3.4.1	Reducción de Latencia	72
3.4.2	Uso de Recursos y Computación de Borde	74
3.4.3	Estimado de Consumo Computacional	75
3.5	Cronograma y Presupuesto	75
3.6	Evaluación de Usabilidad y Experiencia de Usuario	76
CAPÍTULO IV:	Conclusiones y Recomendaciones	82
4.1	Conclusiones	82
4.2	Recomendaciones	83
4.3	Trabajos Futuros	84
REFERENCIAS		85
GLOSARIO		88
ANEXO A:	Repositorio de Código y Configuraciones Técnicas	90
ANEXO B:	Instrumento de Evaluación de Usabilidad	92
ANEXO C:	Formulario de Consentimiento Informado	94
ANEXO D:	Aprobación de Abstract	95

Índice de Tablas

1	Estructura Analítica del Contexto Macro, Meso y Micro de Adopción de IA.	19
2	Antecedentes Institucionales de Investigación en IA y Sistemas Multimodales (UTI).	23
3	Comparativa del Proyecto Propuesto frente al Estado del Arte.	26
4	Matriz de Indicadores de Impacto Potencial del Proyecto.	33
5	Contraste Cuantitativo del Diagnóstico Operativo vs. Asistente Virtual Multimodal.	41
6	Área de estudio.	42
7	Aplicación de la metodología DSRM en el proyecto. . .	43
8	Requerimientos Funcionales del Sistema.	46
9	Requerimientos No Funcionales del Sistema.	50
10	Matriz Comparativa: Proceso Manual vs. Asistente Virtual.	62
11	Pruebas funcionales del módulo de visión artificial. . . .	71
12	Matriz final de validación de requerimientos.	72
13	Registro Piloto de Prueba de Campo y Latencia Extrema a Extremo.	73
14	Evaluación cuantitativa del motor de recuperación semántica.	74
15	Consumo de memoria en el servidor durante picos de inferencia.	74
16	Presupuesto referencial de implementación y operación.	75
17	Cronograma de ejecución del proyecto.	76

Índice de Figuras

1	Ilustración geométrica de la Similitud del Coseno en el espacio vectorial RAG.	36
2	Diagrama de Contexto (Nivel 0).	54
3	Diagrama de Clases del Backend.	55
4	Diagrama de Secuencia de Interacción.	56
5	Diagrama de Estados del Avatar.	57
6	Arquitectura Lógica y flujo de datos del Asistente Virtual (Actualizado).	59
7	Interfaz de acceso y autenticación inicial al Asistente Virtual.	63
8	Comparativa del uso de CPU y GPU entre métodos de visión artificial.	65
9	Panel de Administración del RAG para actualizar mallas curriculares.	66
10	Diagrama de delegación y procesamiento de voz asíncrono en el backend.	67
11	Diagrama de bloques de la Interfaz Dual y composición de elementos web.	67
12	Modo Chat Tradicional del Asistente Virtual.	68
13	Modo Conversacional Inmersivo (Avatar en primer plano con controles de voz).	68
14	Nivel de avance actual de los estudiantes encuestados.	76
15	Frecuencia de interacción previa con IA generativa.	77
16	Conocimiento técnico en renderización 3D.	77
17	Percepción de integración de los módulos del sistema.	77
18	Claridad y precisión de la información académica.	78
19	Gestión de mensajes de error o fallos técnicos.	78
20	Comprensión precisa de las intenciones del usuario.	79
21	Relevancia y utilidad de las respuestas de la IA.	79

22	Capacidad de reconducción ante malentendidos. . . .	80
23	Preferencia futura de uso del asistente virtual.	80
24	Formulario de consentimiento informado.	94
25	Aprobación del Abstract.	95

Índice de Ecuaciones

1	Cálculo lógico para detección de presencia del usuario vía WebSockets	64
2	Media aritmética de la latencia (TTFB)	73
3	Desviación estándar de los tiempos de respuesta	73
4	Intervalo de Confianza al 95 %	73
5	Tasa de Acierto de Recuperación Semántica (Hit Rate) . . .	74

Índice de Anexos

Anexo A: Repositorio de Código y Configuraciones Técnicas . . .	90
Anexo B: Instrumento de Evaluación de Usabilidad	92
Anexo C: Formulario de Consentimiento Informado	94
Anexo D: Aprobación de Abstract	95

UNIVERSIDAD INDOAMÉRICA
FACULTAD DE INGENIERÍAS
INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN

TEMA: DESARROLLO DE UN PROTOTIPO DE ASISTENTE VIRTUAL INTELIGENTE CON INTERFAZ DE AVATAR 3D Y VISIÓN ARTIFICIAL PARA LA DIFUSIÓN DE INFORMACIÓN ACADÉMICA DE LOS ESTUDIANTES DE UNA INSTITUCIÓN EDUCATIVA

AUTOR(A): Paulo Emilio Espinoza Jiménez

TUTOR(A): Ing. Christian Eduardo Iza
Llumiguísín

RESUMEN EJECUTIVO

El presente Trabajo de Integración Curricular aborda la problemática de los actuales repositorios documentales e interfaces institucionales en la difusión de información académica, los cuales carecen de búsqueda semántica y de interactividad proactiva, generando demoras en consultas rutinarias de estudiantes y una sobrecarga administrativa en las secretarías. Con el objetivo de desarrollar un prototipo de asistente virtual inteligente con interfaz de avatar 3D y visión artificial para la difusión de reglamentos y mallas curriculares, se adoptó la Metodología de Investigación en Ciencia de Diseño (DSRM) combinada con el marco de trabajo ágil Scrum para la construcción iterativa del software. La arquitectura híbrida propuesta implementa localmente en el dispositivo cliente la captura visual por cajas delimitadoras y el renderizado gráfico 3D en WebGL, mientras que el servidor local orquesta un motor de Generación Aumentada por Recuperación (RAG) con el modelo de incrustaciones multilingües paraphrase-multilingual-MiniLM-L12-v2 y el modelo local Nemotron. Los principales resultados obtenidos demuestran una alta precisión semántica con un índice de acierto (*Hit Rate*) del 92.0 % en la recuperación de normativas académicas, un tiempo de respuesta (TTFB) promedio de 450 ms que asegura fluidez conversacional mediante WebSockets, y una evaluación de usabilidad positiva con 13 estudiantes en factores de integración, precisión y preferencia de uso. En conclusión, la arquitectura descentralizada y el uso de inteligencia artificial generativa ofrecen una solución viable y robusta que transforma la consulta estática tradicional en un canal de soporte interactivo, accesible y eficaz para la comunidad universitaria.

DESCRIPTORES: Asistente virtual, inteligencia artificial generativa, interacciones multimodales, renderizado 3D

UNIVERSIDAD INDOAMÉRICA
FACULTY OF ENGINEERING
BACHELOR'S DEGREE IN INFORMATION TECHNOLOGY
ENGINEERING

TOPIC: DEVELOPMENT OF A SMART VIRTUAL ASSISTANT PROTOTYPE WITH 3D AVATAR INTERFACE AND COMPUTER VISION FOR THE DISSEMINATION OF ACADEMIC INFORMATION TO STUDENTS OF AN EDUCATIONAL INSTITUTION

AUTHOR: Paulo Emilio Espinoza Jiménez

ADVISOR: Ing. Christian Eduardo Iza
Llumiguísín

ABSTRACT

This Curricular Integration Project addresses the limitations of current document repositories and institutional interfaces in disseminating academic information, which lack semantic search capabilities and proactive interactivity, leading to delays in routine student queries and administrative overload in administrative offices. Aiming to develop a prototype of an intelligent virtual assistant with a 3D avatar interface and computer vision for the dissemination of academic regulations and curricula, the Design Science Research Methodology (DSRM) was adopted in combination with the agile Scrum framework for iterative software development. The proposed hybrid architecture implements visual capture via bounding boxes and 3D graphic rendering using WebGL locally on the client device, while a local server orchestrates a Retrieval-Augmented Generation (RAG) engine utilizing the multilingual embedding model alongside the local Nemotron model. The main results demonstrate high semantic accuracy, achieving a Hit Rate of 92.0 % in academic regulation retrieval, an average Time to First Byte (TTFB) response time of 450 ms ensuring conversational fluency via WebSockets, and a positive usability evaluation with 13 students regarding integration, accuracy, and usage preference. In conclusion, the decentralized architecture and the use of generative artificial intelligence provide a viable, robust solution that transforms traditional, static queries into an interactive, accessible, and efficient support channel for the university community.

KEYWORDS: Generative artificial intelligence, Multimodal interactions, Virtual assistant, 3D rendering

CAPÍTULO I

INTRODUCCIÓN

1.1 Contextualización

La adopción de tecnologías emergentes de Inteligencia Artificial (IA) en la educación superior se articula a través de tres niveles interdependientes de análisis: macroeconómico y nacional, meso o inter-institucional metropolitano, y micro o específicamente universitario.

En el **contexto Macro (Ecuador)**, según el *Índice Latinoamericano de Inteligencia Artificial (2024-2025)* [1], el país es catalogado en una etapa de “adopción tardía”, pero con un crecimiento acelerado en el desarrollo de talento tecnológico e infraestructuras digitales. En la educación superior ecuatoriana, un estudio reciente demostró que el 87,3 % de los estudiantes universitarios reporta haber utilizado herramientas basadas en IA para fines formativos [2], cifra que alcanza un 94,2 % entre alumnos de facultades técnicas y científicas como la Ingeniería en Tecnologías de la Información. Los asistentes generativos conversacionales son utilizados por el 82,7 % de la población estudiantil; sin embargo, esta penetración ocurre predominantemente “desde abajo”, de manera autodidacta y paralela a las plataformas oficiales, evidenciando la necesidad imperativa de contar con canales y estrategias institucionales formalmente gobernadas [3].

En el **contexto Meso (Universidades de Quito)**, diversas instituciones del distrito metropolitano lideran la adopción aplicada de inteligencia artificial en la automatización académica. La Pontificia Universidad Católica del Ecuador (PUCE) desarrolló *Aurel_AI* para transformar digitalmente su mesa de ayuda universitaria, así como *LegalBot-EC*, un modelo de lenguaje local especializado en normativas legales ecuatorianas [4]. Por su parte, la Universidad San Francisco de Quito (USFQ) y la Universidad Central del Ecuador (UCE) han desplegado modelos y motores locales para procesamiento analítico y soporte interno, preservando la privacidad de la información académica y

demonstrando la viabilidad técnica de sistemas autónomos en la región [1].

En el **contexto Micro (Universidad Tecnológica Indoamérica - UTI)**, la institución —con sedes operativas consolidadas en Quito y Ambato— ha mantenido una oferta formativa orientada a la innovación digital. De acuerdo con los informes institucionales de Rendición de Cuentas [5], la universidad registra una matrícula global que supera los 8.358 estudiantes (7.839 en programas de grado). En específico, la carrera de Ingeniería en Tecnologías de la Información reporta una población matriculada estable de aproximadamente 380 estudiantes activos en sus dos sedes, evidenciando un notable crecimiento en admisiones de primer nivel en el periodo académico reciente (68 nuevos alumnos: 47 en la sede Quito y 21 en la sede Ambato) [5]. Históricamente, la universidad ha superado la marca de 6.300 estudiantes regulares, generando un volumen masivo de consultas operativas que saturan los esquemas tradicionales de secretaría.

La Tabla 1 sintetiza esta estructura analítica y los indicadores críticos de adopción tecnológica en cada dimensión.

Tabla 1: Estructura Analítica del Contexto Macro, Meso y Micro de Adopción de IA.

Nivel de Contexto	Área Geográfica / Institución	Indicador de Adopción IA	Enfoque Tecnológico y Reto
Macro (Nacional)	República del Ecuador (Sistema Educativo Superior)	87,3 % estudiantes usa IA (94,2 % en TI) [1]	Adopción autodidacta “desde abajo”; necesidad de gobernanza formal
Meso (Metropolitano)	Universidades de Quito (PUCE, USFQ, UCE)	Proyectos locales: <i>Aurel_AI</i> , <i>LegalBot-EC</i> [4]	Modelos locales, privacidad de datos y automatización de soporte
Micro (Institucional)	Universidad Tecnológica Indoamérica (UTI - Sede Quito/Ambato)	Matrícula de >8.358 alumnos (~380 en carrera TI) [5]	Evolucionar el portal SGA estático hacia un Asistente Virtual 3D proactivo

El área de aplicación específica para este proyecto es la carrera

de Ingeniería en Tecnologías de la Información, donde se ha identificado que la gestión de la información académica para los estudiantes es predominantemente estática. Actualmente, el acceso a datos críticos sobre mallas curriculares, requisitos de graduación o perfiles profesionales depende de la navegación manual por el sitio web institucional o de la lectura de extensos archivos PDF, lo que deriva en una experiencia de usuario pasiva y demorada.

El entorno universitario actual demanda canales de comunicación más ágiles que respondan a la necesidad de inmediatez de los estudiantes. La situación identificada revela una brecha entre la disponibilidad de la información y la facilidad con la que el usuario puede obtener respuestas precisas a sus inquietudes. Esta dispersión documental no solo dificulta la orientación de los alumnos de nuevo ingreso, sino que también genera una carga de consultas repetitivas que podrían automatizarse. En este contexto, surge la necesidad de modernizar estos puntos de contacto, transformando los repositorios de datos tradicionales en un entorno de consulta dinámico y proactivo que aproveche las tendencias actuales en interfaces humano-computadora.

1.2 Estado del Arte

El presente estado del arte fundamenta la conceptualización, diseño y desarrollo de un Asistente Virtual Inteligente enfocado en la difusión proactiva de información académica para los estudiantes de la carrera de Tecnologías de la Información (TI). Para abordar la complejidad tecnológica y el impacto institucional de esta solución, esta sección se estructura en cuatro dimensiones analíticas principales.

En primer lugar, se presenta un diagnóstico del funcionamiento actual del sistema de información en la Universidad Tecnológica Indoamérica, identificando las fricciones en la experiencia del usuario. En segundo lugar, se expone la evolución tecnológica de los asistentes virtuales, destacando la transición hacia interfaces antropomórficas, como los avatares 3D, y la integración de la visión artificial. En tercer lugar, se analiza la adopción actual de estas tecnologías en diversas instituciones de educación superior en el Ecuador, estable-

ciendo un contexto nacional. Finalmente, la sección concluye con un análisis comparativo exhaustivo que contrasta quince proyectos y referentes científicos similares con la propuesta de esta investigación.

1.2.1 Diagnóstico del Sistema de Información Institucional en la Universidad Tecnológica Indoamérica

Para que la implementación de un asistente virtual sea pertinente y genere un impacto medible, debe resolver problemas operativos específicos dentro de su entorno de despliegue. En la Universidad Tecnológica Indoamérica (UTI), la administración y difusión de la información académica y curricular se gestiona primordialmente a través de su Sistema de Gestión Académica (SGA).

Actualmente, cuando un estudiante de la carrera de TI requiere consultar su avance de malla curricular, prerequisites de asignaturas o normativas de titulación, debe autenticarse en el portal web del SGA mediante credenciales de acceso. Una vez dentro, la recuperación de la información se realiza navegando por diversos menús que, en su mayoría, derivan en la generación de reportes en formato PDF estático, diseñados idealmente para su impresión. Este modelo de interacción representa un paradigma de recuperación de información lineal y pasivo; si el estudiante presenta dudas de interpretación sobre la secuenciación de materias, el documento no ofrece retroalimentación dinámica, obligando al alumno a buscar asistencia presencial, lo que genera demoras y sobrecarga de consultas administrativas repetitivas.

De manera contrastante, la Universidad Indoamérica posee un entorno altamente propicio para la innovación tecnológica. La institución impulsa activamente la investigación aplicada en inteligencia artificial y oferta programas académicos de posgrado especializados en IA, innovación empresarial y desarrollo de entornos virtuales. En este contexto, el prototipo de asistente virtual propuesto no busca reemplazar la infraestructura del SGA, sino acoplarse como una capa de interfaz moderna, transformando los repositorios de datos tradicionales en un canal de servicio inmediato, conversacional y proactivo.

El desarrollo del presente Asistente Virtual Multimodal no constituye un esfuerzo aislado, sino que se inscribe orgánicamente dentro de una sólida trayectoria de innovación e investigación aplicada en

la Universidad Tecnológica Indoamérica. A través de sus centros de investigación —como el Centro de Investigación en Mecatrónica y Sistemas Interactivos (MIST) y el Centro de Investigación en Empresa, Sociedad y Tecnología (ESTec)— la universidad ha ejecutado múltiples proyectos emblemáticos de inteligencia artificial y computación inmersiva que constituyen antecedentes científicos directos para este trabajo:

- **Detección Oncológica mediante Visión Artificial e IA (Proyecto MIST-CEDIA):** En alianza con la Corporación Ecuatoriana para el Desarrollo de la Investigación y la Academia (CEDIA), la UTI lidera un proyecto I+D+i de modelamiento de procesos biológicos e imágenes médicas para el análisis y detección temprana del cáncer de mama [6]. Este antecedente consolida el dominio computacional de la institución en visión artificial y algoritmos de detección visual por cajas delimitadoras (*bounding boxes*).
- **Entornos Inmersivos 3D y Pensamiento Crítico en TI:** En la propia carrera de Ingeniería en Tecnologías de la Información, investigadores desarrollaron entornos de simulación en motores gráficos avanzados (*Unreal Engine 5*), logrando incrementar el índice de pensamiento crítico de los estudiantes de un promedio de 3.3/10 a 4.1/10 [7]. Ello demuestra empíricamente que la interacción con interfaces tridimensionales dinámicas mejora el rendimiento y la participación del estudiante.
- **Análisis de Sentimientos mediante PNL:** A nivel de procesamiento semántico, investigadores de la UTI han aplicado técnicas avanzadas de Procesamiento de Lenguaje Natural (PLN) y análisis de Big Data para medir sentimientos y percepciones institucionales en medios digitales [8].
- **Evaluación Formativa Asistida por IA en Posgrados y Capacitación Docente:** La institución ha impulsado proyectos de evaluación continua asistida por IA para mitigar sesgos en programas académicos, al tiempo que ha capacitado a su profesorado en inteligencia artificial con expertos de talla mundial para posicionarse como un nodo de innovación iberoamericano [5].

La Tabla 2 sistematiza los proyectos internos previos que sirven como cimiento metodológico y computacional para la integración del avatar 3D y el motor RAG conversacional en la carrera de TI.

Tabla 2: Antecedentes Institucionales de Investigación en IA y Sistemas Multimodales (UTI).

Proyecto Institucional	Unidad / Centro UTI	Tecnología Aplicada	Aporte al Asistente de Tesis
Proyecto MIST-CEDIA [6]	Centro MIST / CEDIA	Visión artificial, imágenes y <i>Deep Learning</i>	Arquitectura de detección visual en tiempo real (<i>bounding boxes</i>)
Simulaciones 3D en TI [7]	Facultad TI	Motor gráfico 3D (<i>Unreal Engine 5</i>)	Validación del impacto de interfaces 3D en el compromiso estudiantil
Análisis Sentimientos PNL [8]	Facultad TI / ESTec	Procesamiento de Lenguaje Natural y Big Data	Comprensión semántica del lenguaje y consultas informales
Evaluación Formativa IA [5]	Posgrados / Docencia	IA generativa en aulas virtuales	Integración curricular sin sesgos y estandarización del servicio

1.2.2 Evolución Tecnológica: Asistentes Virtuales, Avatares 3D y Visión Artificial

La evolución de las interfaces humano-computadora en el ecosistema educativo ha transitado desde chatbots transaccionales basados puramente en texto hacia agentes conversacionales encarnados o multimodales. Si bien los modelos basados en texto logran automatizar respuestas, la evidencia empírica en la educación superior subraya que la dotación de características antropomórficas a los sistemas facilita la creación de entornos centrados en el estudiante, promoviendo la empatía y la presencia social [9].

La integración de Modelos de Lenguaje Grande (LLM) dota al sistema de comprensión semántica, mientras que plataformas de middleware proporcionan la materialización visual. Estas plataformas per-

miten la generación de avatares 3D de alta fidelidad, equipados con mallas faciales configuradas para soportar animaciones expresivas y sincronización labial en tiempo real, lo que reduce la carga cognitiva y humaniza el proceso de difusión de la información [10].

Simultáneamente, la visión artificial (*Computer Vision*) ha transformado a estos asistentes de respondedores pasivos a sistemas capaces de interpretar señales visuales básicas de interacción. Mediante algoritmos de aprendizaje profundo, redes neuronales convolucionales y extracción de puntos de referencia faciales (*landmarks*), un asistente con interfaz de avatar puede adaptar su comportamiento visual, orientar su mirada simulada y mejorar la naturalidad de la comunicación con el usuario [11].

No obstante, la literatura reciente enfatiza la extrema precaución ética que requiere el uso de señales visuales en entornos educativos. Este antecedente dicta un mandato de “privacidad por diseño” para la presente tesis: los algoritmos de visión artificial deben procesar la información de manera efímera, sin almacenar imágenes ni identificar personalmente al alumno sin su consentimiento expreso [12].

1.2.3 Adopción de Inteligencia Artificial en Universidades del Ecuador

El análisis del estado del arte demuestra un creciente interés por la automatización de procesos académicos en las instituciones de educación superior del Ecuador. Diversas universidades se encuentran en etapas de investigación o implementación de soluciones basadas en inteligencia artificial que sirven como antecedentes directos para este proyecto:

- **Universidad Técnica Particular de Loja (UTPL):** Investigadores de esta institución han desarrollado propuestas de asistentes virtuales desplegados mediante tecnología holográfica para optimizar los servicios estudiantiles y reducir tiempos de espera [13]. Además, la universidad ha liderado proyectos de realidad extendida, implementando un “Campus 3D” donde los usuarios navegan a través de avatares.
- **Universidad Politécnica Salesiana (UPS):** Implementó un asistente virtual fundamentado en procesamiento de lenguaje natural

y aprendizaje automático, mediante redes neuronales recurrentes, para gestionar eficientemente la comunicación con aspirantes a estudios de posgrado a través de canales de mensajería, optimizando los recursos administrativos [14].

- **Pontificia Universidad Católica del Ecuador (PUCE):** Con el respaldo de su grupo de investigación en inteligencia artificial, se desarrolló “TELIA”, un asistente virtual integrado en Microsoft Teams para automatizar y transformar digitalmente la resolución de problemas en las mesas de servicios tecnológicos [15].
- **Escuela Superior Politécnica del Litoral (ESPOL):** Se diseñó una plataforma web con un asistente virtual basado en IA y modelos de *machine learning*, como Random Forest, capaz de interpretar preguntas en lenguaje natural para proporcionar indicadores de desempeño predictivos, reduciendo los tiempos de consulta de casi una hora a once minutos [16].
- **Universidad Internacional del Ecuador (UIDE) y Universidad Tecnológica ECOTEC:** Ambas instituciones se encuentran a la vanguardia de la innovación educativa nacional. UIDE fomenta ecosistemas académicos enriquecidos por IA, mientras que ECOTEC utiliza tecnologías avanzadas, incluyendo sistemas de reconocimiento facial para el acceso seguro al campus y el uso de internet de las cosas.

1.2.4 Análisis Comparativo de Soluciones y Proyectos Similares

A continuación, la Tabla 3 expone un contraste analítico entre el prototipo propuesto en esta investigación y diversos referentes bibliográficos y tecnológicos de relevancia, detallando sus objetivos, metodologías de interfaz y el uso de la visión computacional.

Tabla 3: Comparativa del Proyecto Propuesto frente al Estado del Arte.

Proyecto / Autores	Objetivo principal	Interfaz de usuario	Uso de visión artificial	Diferencia principal con el proyecto propuesto
Proyecto Propuesto (Tesis TI - Indoamérica)	Transformar la consulta documental de mallas y normativas en una experiencia dinámica y ágil.	Avatar 3D + procesamiento de lenguaje natural por voz.	Análisis visual no biométrico para apoyar la interacción del avatar.	Especializado en la resolución de la fricción documental específica de la carrera de TI, uniendo gestión curricular con una interfaz multimodal de orientación académica.
NAIA Framework [10]	Asistencia académica general mediante una arquitectura de cinco roles.	Avatar 3D (Ready Player Me) + modelos LLM.	Analiza el entorno visual para retroalimentar la interacción.	NAIA abarca procesos generales para toda la universidad; la propuesta actual acota el razonamiento a normativas de TI, evitando respuestas ambiguas.
EverydAI [17]	Asistencia en la toma de decisiones cotidianas, como cocina, moda y fitness.	Avatar 3D diferenciado por dominio de conocimiento.	Detección de objetos físicos en tiempo real.	Está orientado al entorno doméstico; el proyecto adapta esa capacidad multimodal proactiva al ecosistema burocrático universitario.
Asistente Holográfico UTPL				

Continúa en la siguiente página

Proyecto / Autores	Objetivo principal	Interfaz de usuario	Uso de visión artificial	Diferencia principal con el proyecto propuesto
[13]	Responder consultas frecuentes para servicios estudiantiles.	Despliegue mediante holograma.	No reporta visión proactiva para interacción autónoma.	Utiliza proyección holográfica reactiva; la tesis propone un avatar 3D integrado a un prototipo software de orientación académica.
Asistente Posgrado UPS				
[14]	Reducir la carga de admisiones mediante respuestas automatizadas.	Interfaz textual vía WhatsApp y Messenger.	No utiliza visión artificial.	Es un sistema pasivo basado en texto; el proyecto propuesto humaniza el servicio al dar un rostro y voz 3D a la institución.
TELIA Mesa Ayuda PUCE				
[15]	Automatización de soporte y tickets tecnológicos.	Chatbot integrado en Microsoft Teams.	No utiliza visión artificial.	Es una solución transaccional corporativa; la tesis propone un agente de difusión académica con representación visual mediante avatar 3D.
Asistente Desempeño ESPOL				
[16]	Proporcionar métricas predictivas industriales.	Plataforma web conversacional.	No utiliza visión artificial.	Mantiene un enfoque predictivo de datos tabulares, sin elementos de presencia social ni contexto espacial.

Continúa en la siguiente página

Proyecto / Autores	Objetivo principal	Interfaz de usuario	Uso de visión artificial	Diferencia principal con el proyecto propuesto
GPTAvatar [9]	Crear un entorno educativo inmersivo de código abierto.	Avatar 3D en motor gráfico Unity.	No se enfoca en la detección física del entorno del usuario.	Es una herramienta generalista; el proyecto de tesis se orienta a un servicio institucional sustentado en bases documentales específicas.
Control de Mirada ECAs [11]	Mejorar la toma de turnos en espacios públicos ruidosos.	Agente conversacional en pantalla.	Detección del orador activo para dirigir la mirada del avatar.	El estudio se enfoca en el algoritmo visual-acústico; la tesis es una plataforma integral de recuperación de información.
Medición de Compromiso [12]	Medir niveles de atención en educación virtual.	Modelo analítico sin interfaz avatar definida.	Redes ST-GCN y <i>landmarks</i> faciales.	Es un algoritmo aislado; el proyecto propuesto puede integrar estas lógicas para adaptar dinámicamente la explicación del avatar.
Asistente de Tesis UPN				

Continúa en la siguiente página

Proyecto / Autores	Objetivo principal	Interfaz de usuario	Uso de visión artificial	Diferencia principal con el proyecto propuesto
[18]	Apoyar la estructuración metodológica de trabajos de grado.	Chatbot de texto basado en IA.	No utiliza visión artificial.	Apoya la generación de contenido investigativo; el proyecto propuesto no interviene en tareas, sino en la burocracia administrativa.
Simulaciones Médicas UMH [19]	Entrenamiento diagnóstico para estudiantes de medicina.	Avatar 3D de paciente clínico.	No implementa visión artificial proactiva.	La interacción se orienta a evaluación de competencias, frente a la naturaleza informativa y guiada de la propuesta de TI.
TalkMateAI [20]	Desarrollar un compañero de IA multimodal de ejecución local.	Avatar 3D web.	Modelos visión-lenguaje ligeros.	Es una arquitectura técnica de código abierto; la tesis adopta estos principios de baja latencia para un caso de uso académico real.
AI Desktop Assistant [21]	Mejorar la interacción mediante reconocimiento visual de escritorio.	Asistente en PC.	Reconocimiento visual de gestos y objetos mediante webcam.	Está orientado al control del sistema operativo, a diferencia de la orientación a servicios curriculares del prototipo de tesis.
Modelo Alerta Transporte				

Continúa en la siguiente página

Proyecto / Autores	Objetivo principal	Interfaz de usuario	Uso de visión artificial	Diferencia principal con el proyecto propuesto
[22]	Prevención de aglomeraciones mediante detección visual.	Interfaz de administración de alertas.	Detección de altas concentraciones de personas.	Está orientado a seguridad y flujos masivos; el proyecto propuesto utiliza la detección para iniciar un diálogo uno a uno de manera empática.

1.3 Planteamiento del Problema

En el actual ecosistema de educación superior, la inmediatez y la accesibilidad a la información son factores determinantes para el éxito y la retención estudiantil. En la carrera de Ingeniería en Tecnologías de la Información de la Universidad Tecnológica Indoamérica, se ha identificado una brecha tecnológica significativa en la capa de interacción entre los estudiantes y los repositorios de información institucional.

Actualmente, la gestión de datos académicos críticos tales como mallas curriculares, requisitos de titulación, procesos de prácticas preprofesionales y perfiles de egreso se realiza a través de un modelo predominantemente estático. Las causas de esta problemática radican en que los sistemas de información heredados fueron diseñados bajo un paradigma de almacenamiento y lectura lineal, obligando al estudiante a navegar manualmente por múltiples menús del sitio web institucional o a descargar y leer extensos archivos en formato PDF.

Los efectos de esta infraestructura recaen directamente sobre la experiencia del usuario, volviéndola pasiva, cognitivamente exhaustiva y demorada. Esta dispersión documental dificulta severamente la orientación autónoma, especialmente para los alumnos de nuevo ingreso. Ante la incapacidad de los documentos estáticos para resolver dudas de interpretación o casos específicos, los estudiantes se ven forzados a recurrir a la atención presencial. En consecuencia, se genera un cuello de botella operativo, sobrecargando al personal administrativo y docente con un alto volumen de consultas repetitivas que, bajo un esquema tecnológico adecuado, son inherentemente automatizables.

1.4 Justificación

La modernización de los canales de comunicación universitaria es un imperativo frente a una generación de estudiantes nativos digitales que demandan respuestas ágiles e interactivas. Este proyecto se justifica por su capacidad para transformar un modelo de consulta obsoleto en una experiencia dinámica, centralizada y tecnológica-

mente inmersiva mediante la implementación de un Asistente Virtual Inteligente.

1.4.1 Utilidad

La utilidad principal del prototipo radica en proporcionar un mecanismo complementario de acceso a información académica mediante lenguaje natural, reduciendo la necesidad de navegar manualmente por documentos extensos o múltiples secciones institucionales. La arquitectura RAG permite vincular las respuestas del asistente con una base documental previamente seleccionada, mientras que la interfaz multimodal busca ofrecer una interacción más natural mediante texto, voz y avatar 3D.

1.4.2 Beneficiarios

Los beneficiarios directos son los estudiantes de la carrera de Tecnologías de la Información, quienes dispondrían de un canal adicional para consultar información académica general. De manera indirecta, la disponibilidad de un mecanismo automatizado podría contribuir a reducir determinadas consultas repetitivas dirigidas al personal administrativo; sin embargo, la cuantificación de esta reducción requiere un seguimiento posterior en condiciones reales de operación.

1.4.3 Factibilidad e Impacto Potencial

La ejecución de este proyecto es factible tanto a nivel técnico como operativo. Actualmente existen frameworks de inteligencia artificial, APIs de síntesis de voz, librerías de visión artificial y plataformas de creación de avatares que son altamente accesibles para integrarse en un prototipo funcional de software. Además, el proyecto posiciona a la Universidad Indoamérica a la vanguardia en la adopción de interfaces humano-computadora avanzadas.

Para ilustrar el impacto potencial del proyecto en la carrera de Ingeniería en Tecnologías de la Información, se ha diseñado la matriz comparativa de la Tabla 4. En ella se contrastan los indicadores críticos de la situación actual frente a la proyección técnica del Asistente Virtual Inteligente.

Tabla 4: Matriz de Indicadores de Impacto Potencial del Proyecto.

Indicador	Situación Actual	Proyección del Prototipo	Interpretación
Población potencial beneficiaria	Aproximadamente 380 estudiantes de TI	Acceso al prototipo para consulta de mallas y normativas	Cobertura potencial de la población objetivo
Consulta de información	Navegación manual por sistemas y documentos PDF	Consulta mediante lenguaje natural	Simplificación del mecanismo de consulta
Recuperación de información	Búsqueda manual o por palabras clave	<i>Hit Rate</i> Top-3 de 92,0 %	El fragmento relevante se recuperó entre los tres primeros resultados en el 92 % de las pruebas
Tiempo tecnológico de respuesta	No aplica directamente	Métricas de latencia medidas en el prototipo	Permite evaluar la viabilidad de interacción conversacional
Disponibilidad potencial	Dependiente del horario de los canales administrativos	El software puede operar fuera del horario administrativo	Capacidad potencial de ampliar el horario de consulta

1.5 Objetivos

1.5.1 Objetivo General

Desarrollar e implementar un prototipo de Asistente Virtual Inteligente, provisto de una interfaz de avatar 3D y visión artificial, para optimizar la difusión proactiva y el acceso a la información académica de los estudiantes en la carrera de Ingeniería en Tecnologías de la Información de la Universidad Tecnológica Indoamérica.

1.5.2 Objetivos Específicos

- Analizar los procesos actuales de gestión y consulta de documentación académica en la institución mediante revisión documental y observación directa, para determinar los requerimientos funcionales, no funcionales y la base de conocimiento conversacional del sistema.
- Diseñar la arquitectura de software del asistente mediante un enfoque modular cliente-servidor, definiendo la integración del módulo conversacional, el motor RAG, la base de conocimiento académica, los servicios de voz y el entorno gráfico del avatar 3D.
- Implementar el prototipo del asistente virtual integrando los modelos de inteligencia artificial locales, la interfaz antropomórfica web y los mecanismos de interacción visual no biométrica, para obtener una prueba de concepto interactiva funcional.
- Evaluar el desempeño, rendimiento y usabilidad del prototipo mediante pruebas de interacción con una muestra de estudiantes y métricas computacionales (latencia, uso de recursos), para validar empíricamente la viabilidad técnica de la solución propuesta.

1.6 Alcance del Proyecto

El proyecto comprende el diseño, desarrollo y validación de un prototipo funcional de asistente virtual, orientado exclusivamente a los estudiantes de la carrera de Tecnologías de la Información.

Componentes y funcionalidades incluidas:

- **Módulo de Visión Artificial:** Integración de mecanismos visuales no biométricos para apoyar la interacción del avatar, sin identificar personalmente al usuario ni condicionar el funcionamiento del sistema a infraestructura física específica.
- **Módulo Conversacional (PLN):** Implementación de un motor de Inteligencia Artificial capaz de comprender y procesar solicitudes orales en lenguaje natural (Speech-to-Text), procesar la respuesta mediante un Modelo de Lenguaje Grande (LLM) contextualizado con la información de la carrera (mallas, reglamentos), y emitir una respuesta en audio (Text-to-Speech).
- **Interfaz de Avatar 3D:** Desarrollo de una interfaz gráfica que integre un avatar antropomórfico con capacidad de sincronización labial (*lip-sync*) en tiempo real, generando una interacción inmersiva.

Límites y exclusiones:

- El sistema **no** realizará reconocimiento facial biométrico para la identificación personal del estudiante, preservando la privacidad y operando de forma anónima (Privacidad por Diseño).
- El asistente **no** tendrá integración transaccional directa con la base de datos del Sistema de Gestión Académica (SGA) para realizar acciones como matriculación, pago de aranceles o modificación de notas. Su función será estrictamente informativa y de orientación.
- **No** se desarrollará una versión de aplicación móvil ni despliegue web masivo; el alcance tecnológico se delimita a una prueba de concepto funcional en un entorno de software controlado.

1.7 Fundamentación Teórica

Para respaldar el desarrollo de la arquitectura del Asistente Virtual Inteligente, el proyecto se asienta sobre los siguientes ejes teóricos y tecnológicos:

1.7.1 Inteligencia Artificial y Procesamiento de Lenguaje Natural (PLN)

El PLN es la rama de la IA que permite a las computadoras entender, interpretar y manipular el lenguaje humano. Para que el asistente pueda brindar información académica precisa, se requiere el uso de Modelos de Lenguaje Grandes (LLMs). En este proyecto se fundamentará el uso de técnicas como la Generación Aumentada por Recuperación (RAG, por sus siglas en inglés), que permite al modelo consultar una base de datos de conocimiento específico (los reglamentos y mallas de la UTI) antes de generar una respuesta, evitando así las alucinaciones del modelo.

En el paradigma RAG, los documentos son fragmentados (*chunking*) y transformados a vectores multidimensionales (*embeddings*). Durante la búsqueda, la precisión semántica de la consulta del usuario se evalúa matemáticamente mediante la **Similitud del Coseno** (Figura 1), que mide el ángulo entre el vector de la consulta ($\vec{q}$) y el vector del documento ($\vec{d}_i$) en el espacio latente. Una mayor similitud semántica se traduce en un menor ángulo θ .




Figura 1: Ilustración geométrica de la Similitud del Coseno en el espacio vectorial RAG.

1.7.2 Visión Artificial e Interacción Visual no Biométrica

La visión artificial permite a las máquinas extraer información significativa de imágenes o videos. En este proyecto, su uso se delimita al apoyo de la interacción visual del avatar, sin realizar identificación personal ni almacenamiento de datos biométricos. Se abordarán modelos ligeros capaces de interpretar señales visuales generales para mejorar la naturalidad de la interfaz, manteniendo el principio

de privacidad por diseño.

1.7.3 Agentes Conversacionales Encarnados (ECAs) y Avatares 3D

Los ECAs (Embodied Conversational Agents) son entidades generadas por computadora que poseen una representación visual y habilidades conversacionales. Se investigarán los principios de la Interacción Humano-Computadora (HCI) relacionados con el efecto *Uncanny Valley* y la carga cognitiva. A nivel de software, se explorarán estándares de la industria como WebGL, Three.js y plataformas como Ready Player Me, que proporcionan mallas 3D (*meshes*) estandarizadas y *blendshapes* (morph targets) necesarios para lograr una sincronización labial precisa basada en los fonemas del audio generado.

1.7.4 Arquitectura de Software para Asistentes Virtuales Multimodales

El proyecto requiere una comprensión arquitectónica que integre el motor conversacional, la base de conocimiento, los servicios de voz, el módulo visual no biométrico y la interfaz gráfica del avatar 3D. Se definirán los conceptos de computación local y computación en la nube, justificando qué procesos pueden ejecutarse en el equipo del prototipo para minimizar la latencia y qué procesos, como la generación de respuestas mediante LLM, pueden depender de peticiones a servicios externos mediante APIs RESTful.

CAPÍTULO II

METODOLOGÍA

2.1 Diagnóstico de la Situación Actual

La gestión actual de la información académica en la carrera de Tecnologías de la Información de la Universidad Tecnológica Indoamérica (UTI) se apoya en una infraestructura transaccional robusta conocida como Sistema de Gestión Académica (SGA). Si bien este sistema cumple eficientemente con los procesos de matriculación y registro de calificaciones, presenta limitaciones significativas en su capa de difusión de información de consulta rápida.

Actualmente, cuando un estudiante necesita resolver inquietudes operativas —como la secuenciación de prerrequisitos en su malla curricular, modalidades de titulación o reglamentos de prácticas preprofesionales— el flujo de interacción es puramente estático y asíncrono. El estudiante debe autenticarse en el portal, navegar a través de una arquitectura de información basada en menús jerárquicos y, finalmente, descargar archivos en formato PDF.

La relevancia de mejorar este proceso de difusión se sustenta en la rigurosidad de las normativas internas. Por ejemplo, el Reglamento de Régimen Académico Interno de la Universidad Tecnológica Indoamérica establece directrices críticas que el estudiante debe interpretar correctamente para no retrasar su progreso académico:

“Las prácticas preprofesionales se realizarán en entornos organizacionales, institucionales, empresariales, comunitarios u otros relacionados al ámbito profesional de la carrera o programa, públicos o privados, nacionales o internacionales, que garanticen el desarrollo de competencias para el ejercicio profesional” (UTI, 2024, Art. 45).

Esta dispersión y complejidad documental exige una interfaz más inteligente. Las principales limitaciones técnicas de este enfoque estático son:

- **Carencia de búsqueda semántica:** Los repositorios actuales dependen de búsquedas por palabras clave exactas o navegación manual. El sistema no comprende “la intención del usuario ni puede extraer párrafos específicos de un documento extenso (por ejemplo, un reglamento de 50 páginas) para responder una duda puntual.
- **Ausencia de proactividad en la interfaz:** El sistema requiere que el usuario inicie la interacción mediante el uso de un periférico tradicional (teclado/ratón), sin aprovechar las capacidades del entorno físico, como la detección de presencia.
- **Sobrecarga administrativa:** Al no existir un primer nivel de soporte interactivo capaz de interpretar las mallas curriculares, los estudiantes que no logran comprender los documentos estáticos acuden presencialmente a las secretarías, generando cuellos de botella para tareas inherentemente automatizables.

Para fundamentar cuantitativamente el diagnóstico de la situación actual y evaluar las deficiencias operativas que resuelve la solución propuesta, se analizaron las métricas institucionales del servicio de orientación académica y atención por secretaría en la carrera de Tecnologías de la Información [5]:

- **Tiempos promedio de consulta manual:** En la actualidad, una consulta tradicional —que involucra la autenticación obligatoria en el SGA, navegación por menús jerárquicos, descarga e interpretación de archivos PDF estáticos (mallas, sílabos o reglamentos institucionales) y, en muchos casos, el desplazamiento físico a la secretaría por dudas de interpretación— consume un tiempo promedio de **45 a 60 minutos por estudiante** [5]. Cuando la orientación se realiza en ventanilla de secretaría académica, el personal de coordinación invierte entre **15 y 20 minutos (0.25 h) por caso**. Asimismo, para consultas canalizadas vía correo electrónico institucional, el tiempo de respuesta varía entre **24 y 48 horas en días laborables**, extendiéndose hasta 12 o 20 días hábiles en revisiones documentales complejas de homologación [3].

- **Volumen de solicitudes y carga laboral administrativa:** En la carrera de Ingeniería en Tecnologías de la Información, con un universo poblacional activo de aproximadamente **380 estudiantes cursando la malla curricular** en las sedes Quito y Ambato [5], un 25 % de los estudiantes realiza de manera recurrente al menos una consulta reglamentaria o curricular al mes. Ello genera alrededor de **300 consultas mensuales** de carácter repetitivo en secretaría académica, demandando aproximadamente **75 a 100 horas-hombre al mes** dedicadas exclusivamente a tareas repetitivas y de baja complejidad cognitiva.

- **Nivel de satisfacción, errores de interpretación e “ilusión de aprendizaje”:** La dependencia de repositorios estáticos y la carencia de indexación semántica propician un índice recurrente de errores en la interpretación de prerrequisitos y normativas de titulación. Además, el estudio latinoamericano de adopción tecnológica muestra que un 74 % de la comunidad académica acepta y demanda interfaces interactivas de asistencia digital [1], confirmando la insatisfacción con los portales estáticos tradicionales.

- **Contraste operativo con el Asistente Virtual Multimodal:** Frente a este diagnóstico, el motor de Generación Aumentada por Recuperación (RAG) multilingüe desarrollado en esta tesis ha demostrado empíricamente una precisión de recuperación semántica del **92,0 %** en mallas y normativas institucionales. El sistema resuelve la consulta de manera instantánea, con un tiempo hasta el primer byte (*Time-to-First-Byte* - TTFB) de **450 milisegundos** y un tiempo total de generación conversacional de **3,2 segundos**, reduciendo el tiempo de consulta estudiantil de 60 minutos a pocos segundos y generando un ahorro operativo estimado de **69 a 85 horas-hombre mensuales** para la administración académica [5].

La Tabla 5 presenta el contraste cuantitativo entre las métricas del sistema actual y la proyección de rendimiento con el Asistente Virtual Multimodal.

Tabla 5: Contraste Cuantitativo del Diagnóstico Operativo vs. Asistente Virtual Multimodal.

Métrica / Variable Operativa	Sistema Actual (Manual / PDF Estático)	Asistente Virtual (RAG + Avatar 3D)	Impacto / Mejora Estimada
Tiempo total de consulta estudiante	45 a 60 minutos (búsqueda y lectura PDF)	3,2 segundos (respuesta semántica conversacional)	Reducción del >95 % en tiempo del usuario
Tiempo de respuesta del servidor (TTFB)	24 a 48 horas vía correo / presencial	450 milisegundos vía WebSockets y LLM local	Inmediatez en línea 24/7
Carga operativa de secretaría (mes)	75 a 100 h-hombre/mes (300 consultas)	Automatización del 92,0 % de dudas recurrentes	Ahorro de 69 a 85 h-hombre/mes
Precisión de recuperación semántica	Baja (búsqueda literal por palabras clave)	92,0 % (<i>Hit Rate</i> RAG en normativas UTI)	Eliminación de errores de interpretación

2.2 Área de Estudio

Tabla 6: Área de estudio.

Dominio:	Inteligencia Artificial y Tecnologías Educativas
Línea de investigación:	Diseño, desarrollo e integración de sistemas basados en arquitecturas web, móviles y sistemas embebidos
Sublínea de investigación:	Aplicación de tecnologías emergentes.
Campo:	Tecnologías de la información y la comunicación (TIC)
Área:	Desarrollo de Software e Interfaces Humano-Computadora
Aspectos:	Procesamiento de Lenguaje Natural (PLN), Visión Artificial, Interacción Multimodal, Renderizado 3D
Objeto de estudio:	Asistente virtual inteligente para difusión de información académica
Periodo de estudio:	Enero 2026 - Julio 2026

2.3 Metodología de Desarrollo o Implementación

Para el desarrollo del proyecto se adoptó como metodología principal la Metodología de Investigación en Ciencia de Diseño (DSRM), debido a que el trabajo se orienta al diseño, construcción y evaluación de un artefacto tecnológico destinado a resolver una problemática específica [23].

Como apoyo para la construcción técnica del prototipo se utilizó un enfoque iterativo e incremental, permitiendo desarrollar y ajustar progresivamente los módulos de recuperación de información, visión artificial, procesamiento de voz y avatar 3D. Este enfoque resultó pertinente debido a la necesidad de realizar pruebas sucesivas sobre modelos de lenguaje, parámetros de recuperación semántica y tiempos

de respuesta.

La aplicación de las etapas de la metodología DSRM en el contexto de este trabajo se sintetiza en la Tabla 7.

Tabla 7: Aplicación de la metodología DSRM en el proyecto.

Etapa DSRM	Aplicación en el proyecto	Evidencia
Identificación del problema	Análisis del acceso actual a información académica	Diagnóstico, Cap. II
Definición de objetivos	Requerimientos funcionales y no funcionales	Sección 2.5
Diseño y desarrollo	Arquitectura RAG, visión, voz y avatar	Secciones 2.6 y 3.2
Demostración	Implementación del prototipo	Capturas y repositorio
Evaluación	Pruebas técnicas y pruebas con estudiantes	Secciones 3.3 y 3.6
Comunicación	Documentación del trabajo y repositorio	Tesis y anexos

El desarrollo iterativo se estructuró en las siguientes fases:

- **Fase 1 - Configuración del Entorno Local y Análisis de Datos:** Se recopilaron, limpiaron y segmentaron (*chunking*) los documentos oficiales en formato PDF para su indexación en la base de datos vectorial local.
- **Fase 2 - Desarrollo del Motor Cognitivo (RAG):** Se implementó la Generación Aumentada por Recuperación. Se probaron modelos de incrustación (*embeddings*) y LLMs optimizados para ejecución en servidor local, iterando hasta reducir las alucinaciones del modelo.
- **Fase 3 - Desarrollo Sensorial (Visión y Voz):** Se programaron algoritmos ligeros de visión artificial para la detección de presencia efímera, y se acoplaron las APIs de Speech-to-Text (STT) y Text-to-Speech (TTS).
- **Fase 4 - Integración Multimodal (Avatar 3D):** Se consolidó el flujo.

El audio generado por el TTS se sincronizó (*lip-sync*) con las mallas faciales del avatar renderizado mediante WebGL.

- **Fase 5 - Pruebas y Ajustes de Rendimiento:** Se desplegó en el servidor local destino. Se realizaron pruebas de estrés para medir el uso de GPU/CPU y la latencia end-to-end de las respuestas.

2.4 Técnicas e Instrumentos de Recolección de Información

Para garantizar la validez científica y el correcto desempeño técnico del prototipo, la recolección de información se dividió en dos etapas metodológicas: la etapa de diagnóstico/desarrollo y la etapa de validación.

2.4.1 Técnicas para la Fase de Diagnóstico y Desarrollo

- **Revisión Documental:** Se empleó para alimentar el núcleo de conocimiento de la IA. El instrumento fue una *matriz de extracción de datos*, donde se catalogaron y normalizaron los textos de mallas curriculares, estatutos y sílabos de la carrera de TI antes de inyectarlos en la base de datos vectorial.
- **Observación Directa No Participante:** Se utilizó para analizar la afluencia y el tipo de interacciones que tienen los estudiantes en las oficinas administrativas, lo que permitió diseñar *prompts* base (instrucciones de sistema) que preparen al asistente virtual para los escenarios de consulta más comunes.

2.4.2 Técnicas para la Fase de Evaluación y Validación

- **Métricas de Registro Automático (*Logging*):** Para evaluar el rendimiento técnico (Requerimientos No Funcionales), el sistema incluyó *scripts* que registraron variables cuantitativas como el tiempo de respuesta del sistema (latencia en milisegundos desde que el usuario deja de hablar hasta que el avatar responde) y el porcentaje de uso de la memoria/procesador del servidor local.
- **Cuestionario de Usabilidad y Experiencia de Usuario:** Para eva-

luar la interacción con el prototipo se diseñó un cuestionario estructurado en escala Likert y diferencial semántico. El instrumento permitió recopilar la percepción de los participantes respecto a integración de componentes, comprensión de las respuestas, apariencia y animacidad del avatar, privacidad percibida, latencia e intención futura de uso.

Para la evaluación de usabilidad se trabajó con una muestra piloto de 13 estudiantes de la carrera de Tecnologías de la Información pertenecientes a diferentes niveles académicos. La evaluación tuvo un carácter exploratorio y estuvo orientada a identificar la percepción inicial de los usuarios y oportunidades de mejora del prototipo, por lo que sus resultados no pretenden generalizarse estadísticamente a la totalidad de estudiantes de la carrera. Se utilizó un muestreo no probabilístico por conveniencia.

2.5 Requerimientos del Proyecto

La definición de los requerimientos establece las directrices técnicas y operativas que el sistema debe cumplir. A continuación se detallan los requerimientos funcionales (RF) y no funcionales (RNF) en formato de tabla para asegurar su trazabilidad.

2.5.1 Requerimientos Funcionales (RF)

Tabla 8: Requerimientos Funcionales del Sistema.

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RF-01	Detección No Biométrica de Presencia	Flujo de video continuo en formato Base64 (640x480 a 15 fps) transmitido por el cliente mediante WebSockets.	El backend evalúa la presencia detectando la caja delimitadora (Bounding Box) del rostro. Si el área ($W \times H$) supera el umbral de píxeles tau durante 3 frames consecutivos, se activa la interacción.	Mensaje lógico en formato JSON {'status': 'active'} para iniciar el avatar en el frontend.	Aprobación del 100 % en condiciones de luz normal (> 150 lux) a una distancia de 50 cm a 1.5 m.
Continúa en la siguiente página					

Tabla 8 – continuación de la página anterior

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RF-02	Transcripción de Voz a Texto (STT)	Fragmento de audio digital en formato WebM capturado asincrónicamente por el micrófono del cliente.	El backend FastAPI extrae el audio y realiza una solicitud API REST HTTPS al modelo Whisper-v3 (en la infraestructura Groq) para transcribir el flujo de audio en español.	String de texto decodificado con la consulta del estudiante en formato UTF-8.	Tasa de error de palabras (WER) < 5 % en un entorno controlado con ruido de fondo < 45 dB.
RF-03	Búsqueda Semántica RAG	Consulta textual del estudiante transcrita o ingresada manualmente por teclado.	Generación de vector de consulta (384 dimensiones) usando paraphrase-multilingual-MiniLM-L12-v2 y cálculo de similitud del coseno contra ChromaDB local.	Lista priorizada de los 3 fragmentos documentales con mayor similitud semántica (Top-3).	Hit Rate de recuperación semántica del Top-3 $\geq 90,0\%$ evaluado con un banco de 50 preguntas piloto.
Continúa en la siguiente página					

Tabla 8 – continuación de la página anterior

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RF-04	Generación de Respuesta por LLM	Contexto académico recuperado (Top-3) insertado dentro de un prompt estructurado de 'Contexto Cerrado'.	Inferencia local en el servidor del LLM Qwen 2.5 / Nemotron a través de Ollama. Si la similitud del coseno de los fragmentos recuperados es inferior a 0.65, el modelo debe rechazar cortésmente la respuesta.	Respuesta de texto precisa y estrictamente verídica basada en los reglamentos oficiales de la UTI.	Tasa de alucinación o invención de datos del 0.0% (Validación ciega por expertos en reglamentos).
RF-05	Síntesis de Texto a Voz (TTS)	Respuesta de texto generada por el LLM.	FastAPI segmenta el texto y realiza llamadas asíncronas a la API de ElevenLabs (voz Valeria), devolviendo el audio mediante fragmentos en tiempo real (HTTP Chunking Streaming).	Flujo binario de audio MP3/WAV reproducido asíncronamente en los altavoces del cliente.	Latencia de inicio de reproducción (Time to First Byte - TTFB) < 500 milisegundos tras recibir el texto del LLM.
Continúa en la siguiente página					

Tabla 8 – continuación de la página anterior

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RF-06	Gestión de Sesión y Retorno a Reposo	Contador lógico de inactividad conversacional activo (timeout timer).	El sistema monitorea la interacción por voz y video. Si no se detectan rostros ni actividad de audio en 45 segundos, se envía señal de despedida.	Mensaje JSON { 'status': 'reposo' } que activa animación de despedida y apaga la cámara y micrófono del cliente.	Prueba de caja negra: retorno inmediato al estado de reposo al cumplirse el timeout (desviación < 1,0s).

2.5.2 Requerimientos No Funcionales (RNF)

Tabla 9: Requerimientos No Funcionales del Sistema.

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RNF-01	Privacidad por Diseño (Seguridad)	Fotogramas e imágenes de cámara web procesados en la memoria RAM del servidor.	Se prohíbe explícitamente guardar imágenes, videos o mallas biométricas en discos locales o bases de datos persistentes. Los frames se destruyen inmediatamente de la memoria tras calcular el bounding box.	Garantía de anonimato absoluto en el uso de la cámara por parte del estudiante.	Verificación mediante auditoría de código del backend y monitoreo de almacenamiento en disco local (0 bytes creados por OpenCV).
Continúa en la siguiente página					

Tabla 9 – continuación de la página anterior

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RNF-02	Rendimiento y Latencia Conversacional	Consulta completa por voz del estudiante.	El pipeline total (STT + RAG + LLM + TTS) debe estar optimizado asíncronamente mediante WebSockets y programación concurrente con asyncio.	Interacción fluida con un tiempo de respuesta total controlado.	Latencia extremo a extremo P95 < 4,0 segundos en la red local universitaria bajo una carga de 1 usuario activo.
RNF-03	Restricción de Dominio Académico	Consultas del usuario con intenciones no académicas o externas.	Evaluación mediante el prompt del sistema. Si la consulta está fuera del ámbito de mallas, reglamentos y titulación de TI, el LLM activa una salida controlada.	Mensaje estándar de denegación cortés: 'Disculpa, solo puedo ayudarte con temas académicos de la carrera de TI.'	Aprobación del 100% de rechazo sistemático ante un set de 20 preguntas capciosas de prueba.
Continúa en la siguiente página					

Tabla 9 – continuación de la página anterior

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RNF-04	Aislamiento y Seguridad de Datos	Arquitectura de base de datos relacional externa de la UTI (SGA).	El sistema de asistente opera en un servidor independiente con ChromaDB, sin credenciales de escritura ni lectura directa a la base transaccional SQL del SGA.	Imposibilidad física de realizar cambios transaccionales en expedientes de alumnos.	Comprobación de que la red del asistente no contiene puertos abiertos ni credenciales de conexión al SGA.
RNF-05	Mantenibilidad y Escalabilidad	Nuevos documentos reglamentarios o actualizaciones de mallas en formato PDF.	El sistema utiliza un portal administrativo protegido por contraseña para procesar nuevos PDF, generar embeddings e insertarlos dinámicamente en ChromaDB.	Actualización del conocimiento del asistente de forma inmediata sin necesidad de fine-tuning.	Tiempo de actualización de un nuevo documento < 60 segundos por parte del administrador de TI.
Continúa en la siguiente página					

Tabla 9 – continuación de la página anterior

Código	Nombre del Requerimiento	Entradas / Estímulo	Procesamiento y Control	Salida / Respuesta	Métrica de Validación y Prueba
RNF-06	Usabilidad Manos Libres (Hands-Free)	Interfaz de usuario en un tótem físico o pantalla institucional.	Toda la navegación e interacción se diseña para operar exclusivamente a través de la cámara de presencia y el micrófono por reconocimiento de voz.	Uso interactivo autónomo sin teclado, ratón o toques físicos de pantalla.	Cumplimiento verificado mediante pruebas con estudiantes: tasa de éxito de consulta completa sin intervención de hardware físico = 100 %.

2.6 Diseño de la Solución

El diseño de la solución propuesta se articula sobre una arquitectura modular y desacoplada, operando bajo un entorno de despliegue en un servidor local para garantizar el rendimiento, la seguridad y el procesamiento en tiempo real. El sistema se desglosa en tres capas lógicas fundamentales:




Figura 2: Diagrama de Contexto (Nivel 0).




Figura 3: Diagrama de Clases del Backend.




Figura 4: Diagrama de Secuencia de Interacción.




Figura 5: Diagrama de Estados del Avatar.

2.6.1 Capa de Percepción y Captura (Frontend Físico)

Esta capa actúa como el sensor del sistema. A través de una cámara web, un modelo ligero de visión artificial procesa el flujo de video en tiempo real. El diseño estipula que el sistema no guardará fotogramas; únicamente extraerá las coordenadas de la caja delimitadora (*bounding box*) del rostro. Cuando el área del rostro supera un umbral específico de píxeles (indicando que el estudiante se ha acercado a la pantalla), el sistema envía un disparador (*trigger*) lógico para “despertar” al asistente. Simultáneamente, un micrófono direccional se activa para capturar la solicitud del usuario.

2.6.2 Capa de Procesamiento Cognitivo (Motor de IA)

Es el núcleo lógico de la solución, estructurado mediante un flujo de datos secuencial:

- **Speech-to-Text (STT):** Transcribe el audio del usuario a texto natural en español utilizando un procesamiento en *backend* (Whisper-v3 vía API), desacoplado del navegador para asegurar compatibilidad y baja latencia.
- **Generación Aumentada por Recuperación (RAG):** El texto ingresa a un motor de búsqueda semántica. Utilizando incrustaciones (*embeddings*), el sistema compara la consulta del estudiante con una base de datos vectorial pre-indexada que contiene las mallas curriculares y reglamentos de la carrera de TI.
- **Modelo de Lenguaje (LLM):** Un modelo de ejecución local recibe la consulta del usuario junto con el contexto extraído por el RAG, generando una respuesta coherente, precisa y libre de alucinaciones.
- **Text-to-Speech (TTS):** El texto generado por el LLM se sintetiza nuevamente a un archivo de audio.

2.6.3 Capa de Renderizado e Interacción (Frontend Gráfico)

El audio sintetizado y la cadena de texto se envían al motor gráfico basado en tecnologías web (WebGL/Three.js). En esta capa reside el Avatar 3D, el cual recibe el archivo de audio, analiza sus fonemas y




Figura 6: Arquitectura Lógica y flujo de datos del Asistente Virtual (Actualizado).

ejecuta algoritmos de sincronización labial (*lip-sync*) para emular el habla natural mientras reproduce animaciones predefinidas (como parpadeo y gestos de manos).

2.7 Justificación Técnica

La viabilidad técnica y operativa del Asistente Virtual Inteligente depende de una rigurosa selección de componentes y plataformas. A continuación, se justifican las decisiones arquitectónicas adoptadas para este proyecto:

2.7.1 Despliegue en Servidor Local (Edge/Local Computing)

A diferencia de las arquitecturas basadas enteramente en la nube, el despliegue del pipeline principal en un servidor local asegura una latencia mínima, aspecto crítico para mantener la fluidez en una conversación humano-computadora. Además, procesar las imágenes de la cámara web de manera local (sin enviarlas a servidores externos) garantiza el cumplimiento estricto del Requerimiento No Funcional de privacidad [11].

2.7.2 Implementación de la Arquitectura RAG frente a Fine-Tuning

Para dotar al LLM del conocimiento institucional, se seleccionó la arquitectura RAG (Retrieval-Augmented Generation) sobre el reentrenamiento (*Fine-Tuning*). La literatura especializada demuestra que el *Fine-Tuning* es computacionalmente costoso y altamente susceptible a alucinaciones cuando se le piden datos exactos [10]. El enfoque RAG permite que la universidad actualice un reglamento (agregando un nuevo PDF a la base de datos) y el asistente adopte el nuevo conocimiento de forma inmediata sin necesidad de reentrenar el modelo, garantizando escalabilidad y bajo costo de mantenimiento.

2.7.3 Visión Artificial mediante Modelos Ligeros

Para el módulo de detección de presencia, se opta por librerías optimizadas para inferencia rápida (como MediaPipe o configuraciones de Haar Cascades). Estas herramientas operan eficientemente sin necesidad de tarjetas gráficas (GPUs) de gama alta, permitiendo que todo el peso computacional del hardware se reserve para la inferencia del Modelo de Lenguaje y el renderizado 3D del avatar.

2.7.4 Plataformas de Avatar Estandarizadas

Se justifica el uso de plataformas de avatares basadas en estándares abiertos (como GLTF o GLB, facilitados por herramientas como Ready Player Me) ejecutadas sobre WebGL en el navegador. Esta decisión técnica evita la dependencia de motores de videojuegos pesados (como Unreal Engine), lo que reduce la carga del sistema operativo y facilita una futura portabilidad del asistente a otras pantallas o terminales de la institución sin requerir configuraciones de software complejas.

CAPÍTULO III

IMPLEMENTACIÓN, PRUEBAS Y RESULTADOS

3.1 Descripción de la Solución

La solución implementada consiste en un prototipo funcional de un Asistente Virtual Inteligente diseñado para la difusión proactiva de reglamentos y mallas curriculares. La arquitectura mantiene localmente el motor de recuperación y los componentes principales de inteligencia artificial, mientras determinados servicios de voz utilizan APIs externas para transcripción y síntesis. La captura de video se realiza desde el dispositivo cliente mediante el navegador. Los fotogramas necesarios para la detección de presencia se transmiten temporalmente al backend mediante WebSockets y son procesados sin almacenamiento persistente. El sistema utiliza exclusivamente la información necesaria para determinar la presencia del usuario y activar la interacción, evitando el almacenamiento persistente de imágenes o plantillas biométricas y limitando el procesamiento visual a la detección temporal necesaria para la interacción.

A continuación, la Tabla 10 resume la evolución operativa lograda mediante este prototipo frente a los procesos institucionales tradicionales.

Tabla 10: Matriz Comparativa: Proceso Manual vs. Asistente Virtual.

Criterio	Antes (Manual/SGA)	Después (Protopipo de IA)
Modo de Interacción	Navegación manual por menús.	Conversacional (Voz natural).
Formato de Respuesta	Archivos estáticos (PDF).	Respuestas orales y visuales exactas.
Esfuerzo del Usuario	Alto (búsqueda y lectura exhaustiva).	Bajo (solo requiere preguntar).
Soporte a Dudas	Acudir a secretaría (demorado).	Capacidad técnica de ofrecer consultas fuera del horario administrativo, condicionada a la disponibilidad de infraestructura.

El sistema está estructurado en tres capas operativas distintas que funcionan bajo un modelo cliente-servidor descentralizado:

- **Capa de Percepción:** Un módulo de visión artificial y captura de audio nativo ejecutado en el cliente web, que interactúa vía WebSockets con el servidor para preservar la privacidad y reducir el ancho de banda.
- **Capa Cognitiva:** Un entorno administrado por FastAPI que orquesta una base de datos vectorial (ChromaDB), modelos de transcripción asíncronos (Whisper-v3) y el modelo LLM local u optimizado por API.
- **Capa de Interacción Frontal:** Interfaz basada en web que renderiza un avatar 3D mediante WebGL.

La Imagen 7 muestra la interfaz de acceso inicial al sistema.




Figura 7: Interfaz de acceso y autenticación inicial al Asistente Virtual.

Elaborado por: Estudiante

Fuente: Captura de pantalla del sistema

3.2 Proceso de Implementación

3.2.1 Implementación de Visión Artificial Ligera y WebSockets

Dado que los servidores virtuales en la nube carecen de periféricos físicos como cámaras web, se modificó el enfoque tradicional de OpenCV local. La solución delega el acceso al hardware al navegador del cliente mediante JavaScript (`navigator.mediaDevices.getUserMedia`). El frontend extrae fotogramas en formato base64 y los envía a través de una conexión bidireccional en tiempo real (*WebSockets*) hacia FastAPI.

El uso de WebSockets facilita una comunicación bidireccional y asíncrona entre cliente y servidor, evitando que las operaciones de entrada y salida mantengan bloqueado innecesariamente el flujo principal durante el procesamiento de las solicitudes. A diferencia de las peticiones HTTP tradicionales, que mantendrían un hilo bloqueado mientras el modelo genera la respuesta de IA, la arquitectura orientada a eventos de los WebSockets permite al servidor procesar los fotogramas visuales y emitir la respuesta en tiempo real de forma asíncrona, sin congelar el flujo de ejecución principal.

Para detectar a los usuarios de manera proactiva sin incurrir en altos costos computacionales, el servidor analiza la caja delimitadora (*bounding box*) del rostro.

$$Estado = \begin{cases} Activo, & \text{si } (W_{box} \times H_{box}) > \tau_{pixeles} \\ Reposo, & \text{de lo contrario} \end{cases} \quad (1)$$

Como se observa en la Figura 8, este enfoque delegado reduce drásticamente el uso computacional de la CPU del servidor, logrando un proceso sostenible y evitando cuellos de botella en la renderización. Las pruebas de rendimiento se ejecutaron bajo condiciones experimentales controladas: un servidor local equipado con un procesador Intel Core i7 de 12.ª generación, 32 GB de memoria RAM, y una GPU dedicada NVIDIA RTX 3060 de 12GB VRAM. La resolución de captura visual se limitó a 640x480 píxeles a 15 cuadros por segundo durante sesiones ininterrumpidas de 10 minutos.




Figura 8: Comparativa del uso de CPU y GPU entre métodos de visión artificial.

3.2.2 Procesamiento de Documentos y Motor RAG Multilingüe

Una mejora fundamental se dio en el motor de Generación Aumentada por Recuperación (RAG). Se identificó que modelos en inglés generaban fallos de recuperación ante consultas en español. Por ello, se implementó el modelo de *embeddings* *paraphrase-multilingual-MiniLM-L12* ajustando el tamaño de fragmentación (*chunking*) a 1500 caracteres con un solapamiento de 300 usando `MarkdownTextSplitter`.

Los documentos son procesados con la biblioteca `pymupdf4llm` para preservar la estructura de tablas y transformados a vectores de 384 dimensiones. Durante la búsqueda, la precisión se evalúa calculando la similitud del coseno (conceptuada en la Sección 2.6.2).

Para manejar el riesgo crítico de las alucinaciones, el motor RAG fue configurado bajo un estricto patrón de “Contexto Cerrado”. Si la métrica de similitud del coseno de los documentos recuperados es inferior al umbral de confianza, el *prompt* del sistema instruye explícitamente al LLM local a declinar la respuesta, evitando interbloqueos lógicos.

La administración dinámica de estos documentos se gestiona a través de un panel especializado, visible en la Imagen 9. El acceso al panel administrativo destinado a la actualización de la base documental debe mantenerse restringido a usuarios autorizados. Las credenciales y claves de los servicios externos se gestionan mediante variables de entorno y no deben almacenarse directamente en el código fuente. Para una futura implementación institucional se reco-

mienda incorporar control de roles, registro de cambios y mecanismos adicionales de auditoría.




Figura 9: Panel de Administración del RAG para actualizar mallas curriculares.

Elaborado por: Estudiante

Fuente: Captura de pantalla del sistema

3.2.3 Procesamiento de Voz Asíncrono (Whisper y ElevenLabs)

Para solucionar la limitación del *Text-to-Speech* robótico tradicional (edge-tts), se implementó una delegación asíncrona dual para la audición y el habla. El usuario graba su voz, y FastAPI delega la transcripción al modelo **Whisper-v3** a través de la API ultrarrápida de Groq. Posteriormente, el texto del LLM es convertido a voz natural (Voz “Valeria”) mediante la API de ElevenLabs con *HTTP Chunking Streaming*.

3.2.4 Interfaz Dual y Renderizado WebGL

La interacción final fue desarrollada utilizando *Three.js* para renderizar un avatar de formato VRM directamente en el navegador (WebGL). Se programaron dos modos visuales (Dual UI Mode): un modo “Chat” tradicional con historial (Imagen 12) y un modo “Conversacional” inmersivo sin texto (Imagen 13).

Como parte del rediseño UI, se desactivó el seguimiento ocular del ratón para mantener profesionalismo y se añadieron burbujas de




Figura 10: Diagrama de delegación y procesamiento de voz asíncrono en el backend.

sugerencias dinámicas usando CSS y posiciones absolutas sobre el Canvas de WebGL.




Figura 11: Diagrama de bloques de la Interfaz Dual y composición de elementos web.

3.3 Pruebas y Validación

3.3.1 Pruebas Técnicas de los Modelos (IA)

Las pruebas técnicas del pipeline de inteligencia artificial se ejecutaron sobre el servidor local equipado con Intel Core i7, 32 GB de RAM y NVIDIA RTX 3060 de 12 GB. De manera complementaria, determinadas pruebas de concurrencia del backend web se realizaron sobre un entorno de DigitalOcean. Ambos escenarios se reportan separadamente para evitar comparar directamente métricas obtenidas sobre infraestructuras diferentes.

Las pruebas individuales de los componentes de inteligencia arti-




Figura 12: Modo Chat Tradicional del Asistente Virtual.

Elaborado por: Estudiante

Fuente: Captura de pantalla del sistema




Figura 13: Modo Conversacional Inmersivo (Avatar en primer plano con controles de voz).

Elaborado por: Estudiante

Fuente: Captura de pantalla del sistema

ficial garantizaron la robustez del pipeline completo:

- **Prueba del Modelo RAG y LLM:** Se evaluó la asertividad del modelo de comprensión (Qwen) al extraer datos de tablas complejas indexadas por `paraphrase-multilingual`. Se superó el 90 % de precisión en la coincidencia semántica en español.
- **Pruebas del Avatar y Síntesis de Voz (ElevenLabs):** Se midió el *Time To First Byte* (TTFB) del streaming de audio, confirmando que la voz iniciaba en menos de 500ms tras la solicitud, permitiendo que la interpolación de formas base (*blendshapes*) para el movimiento labial luzca natural.
- **Pruebas de Transcripción (Whisper-v3):** Se validó la capacidad de la API de Groq para transcribir acentos regionales y términos técnicos (como “malla”, “prerrequisitos”, “sílabo”) sin errores ortográficos.

3.3.2 Pruebas de Concurrencia

Se realizaron pruebas exploratorias de concurrencia mediante Apache JMeter con el propósito de verificar el comportamiento del backend ante solicitudes simultáneas. Los resultados permitieron comprobar el funcionamiento asíncrono del servicio, aunque no se realizó una caracterización exhaustiva de capacidad máxima, por lo que esta evaluación se plantea como línea de profundización futura.

3.3.3 Protocolo de Pruebas con Usuarios

El objetivo principal del instrumento fue medir la calidad de la interacción y la usabilidad desde la perspectiva del estudiante de la carrera de TI. Para ello, se diseñó un protocolo riguroso:

1. Consentimiento Informado y Privacidad: Antes de iniciar, se informó a los participantes sobre el uso de la cámara web para la visión artificial. El protocolo aclaró explícitamente que los fotogramas se procesaban en memoria y eran destruidos inmediatamente, garantizando el anonimato total de la información recopilada.

2. Ejecución de la Prueba: Los usuarios interactuaron con el asistente realizando consultas académicas reales utilizando tanto entrada de texto como micrófono, probando las funciones de entrada y

respuestas de la IA.

3. Diseño del Instrumento de Evaluación: Se estructuró un cuestionario (mediante la plataforma *Google Forms*) para capturar retroalimentación cuantitativa y cualitativa. El instrumento, con una duración aproximada de 5 a 10 minutos por sesión, fue dividido en seis secciones principales evaluando las variables mediante escalas de Likert y Diferenciales Semánticos:

- **Sección 1 - Perfil Técnico del Evaluador:** Preguntas demográficas sobre el nivel de avance en la carrera de TI y frecuencia de uso previo de modelos de IA generativa.
- **Sección 2 - Usabilidad de la Interfaz y Arquitectura:** Evaluó, en una escala del 1 al 5, la integración entre la visión artificial, la entrada de micrófono y la interfaz gráfica general.
- **Sección 3 - Inteligencia Conversacional y NLP:** Cuantificó la capacidad del modelo para comprender intenciones, reconducir conversaciones y brindar respuestas institucionalmente relevantes.
- **Sección 4 - Evaluación de la Interfaz del Avatar 3D:** Utilizó un Diferencial Semántico para calificar al modelo 3D en parámetros de Antropomorfismo (Artificial vs. Natural), Animacidad (Estático vs. Vivo), Afinidad visual e Inteligencia percibida mediante el lenguaje corporal.
- **Sección 5 - Visión Artificial y Aceptación Tecnológica:** Evaluó la percepción del usuario respecto a la latencia, confianza en la privacidad del uso de la cámara y disposición para adoptar esta tecnología frente a portales web tradicionales.
- **Sección 6 - Diagnóstico Técnico:** Pregunta abierta para obtener *feedback* técnico de arquitectura y base de datos antes del despliegue masivo.

3.3.4 Evaluación Funcional de Visión Artificial

La evaluación tuvo un carácter funcional y buscó comprobar que el mecanismo de detección de presencia activara correctamente

el asistente en condiciones representativas de uso. No se pretendió evaluar reconocimiento facial ni identificación biométrica.

Tabla 11: Pruebas funcionales del módulo de visión artificial.

Condición	Escenario	Resultado Observado
Iluminación	Normal (Luz de día u oficina)	El sistema detecta correctamente la presencia del usuario y activa la interfaz.
Iluminación	Baja (Oscuridad o penumbra)	El sistema no logra reconocer la caja delimitadora; no detecta a nadie.
Distancia	Muy cercana (< 30 cm)	El rostro o cuerpo ocupan demasiado encuadre; no detecta por proximidad extrema.
Distancia	Media (50 cm - 1.5 m)	El sistema funciona correctamente; la detección es continua y estable.

3.3.5 Matriz de Validación de Requerimientos

Para asegurar la trazabilidad del desarrollo, la Tabla 12 sintetiza la validación de los requerimientos funcionales y no funcionales del prototipo.

Tabla 12: Matriz final de validación de requerimientos.

Requisito	Evidencia	Resultado	Estado
RF-01 Visión no biométrica	Prueba de detección	Operación funcional	Cumple
RF-02 STT	Pruebas de transcripción	Transcripción asertiva	Cumple
RF-03 RAG	Hit Rate 92.0 %	Recuperación satisfactoria	Cumple
RF-04 LLM	Pruebas funcionales	Generación sin alucinaciones	Cumple
RF-05 TTS	TTFB aprox. 450 ms	Síntesis de voz natural	Cumple
RF-06 Gestión de estados	Prueba funcional	Retorno a reposo correcto	Cumple
RNF-01 Privacidad	Sin persistencia de fotogramas	Anonimato protegido	Cumple
RNF-02 Latencia	TTFT y TTFB medidos	Interacción conversacional	Cumple

3.4 Resultados

3.4.1 Reducción de Latencia

Durante el proceso iterativo de desarrollo se evaluó inicialmente Qwen 2.5 cuantizado como modelo de generación. Posteriormente, la versión final del prototipo incorporó Nemotron debido a su comportamiento en las pruebas de latencia. En consecuencia, las mediciones correspondientes a cada modelo se identifican expresamente en las tablas de resultados.

Las pruebas de rendimiento permitieron distinguir diferentes componentes de la latencia. El servicio de síntesis de voz registró un Time to First Byte (TTFB) aproximado de 450 ms desde el envío de la solicitud al servicio TTS hasta el inicio de la recepción del audio. De manera independiente, el pipeline conversacional presentó un tiempo aproximado de 3,2 segundos para iniciar la generación de la respuesta (*Time To First Token*).

Para evaluar la reducción de latencia de forma rigurosa, se implementó un mecanismo de telemetría interno (*logging*) que registró el tiempo transcurrido desde el envío de la consulta de voz hasta la renderización de la respuesta. Con los datos capturados, se aplicaron

las siguientes fórmulas estadísticas para determinar la fiabilidad del sistema en producción:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (3)$$

$$IC_{95} = 1,96 \times \left(\frac{s}{\sqrt{n}} \right) \quad (4)$$

A continuación, la Tabla 13 muestra el registro piloto de prueba de campo con 10 interacciones para fundamentar los cálculos y validar empíricamente la efectividad del RAG:

Tabla 13: Registro Piloto de Prueba de Campo y Latencia Extremo a Extremo.

ID de Prueba	Usuario (Estudiante)	Latencia (ms)	RAG Top-3	Observación / Contexto
PR-01	Estudiante 1 - 4to Sem	3120	Sí	Consulta sobre prerequisites de Redes I. Luz normal, voz clara.
PR-02	Estudiante 2 - 4to Sem	3450	Sí	Consulta sobre reglamento de prácticas. Voz baja, detectado con éxito.
PR-03	Estudiante 3 - 8vo Sem	4100	Sí	Consulta de modalidades de titulación. Latencia alta en red local.
PR-04	Estudiante 4 - 8vo Sem	2980	Sí	Consulta sobre malla curricular. Respuesta semántica directa.
PR-05	Estudiante 5 - 3er Sem	3200	Sí	Consulta de horarios. Similitud coseno alta (0.85).
PR-06	Estudiante 6 - 3er Sem	3310	Sí	Consulta de reglamentos de homologación. Respuesta contextualizada.
PR-07	Estudiante 7 - 4to Sem	5200	NO	Consulta capciosa sobre deportes. Se activó restricción de dominio.
PR-08	Estudiante 8 - 4to Sem	3050	Sí	Consulta sobre syllabus de Programación. Audio claro.
PR-09	Estudiante 9 - 1er Sem	3500	Sí	Consulta sobre ubicación de laboratorios. Detección por cámara normal.
PR-10	Estudiante 10 - 8vo Sem	3800	Sí	Consulta sobre carpeta de titulación. Ruido de fondo moderado.

Para evaluar rigurosamente el motor de recuperación semántica sin necesidad de reentrenar (*fine-tuning*) el LLM, se utilizó la siguiente fórmula matemática:

$$\text{Hit Rate} = \left(\frac{\text{Consultas Correctas}}{N_{\text{total}}} \right) \times 100 \quad (5)$$

Los resultados globales de la muestra estadística arrojaron una Media de Latencia ($\bar{x}$) de 3571 ms y una precisión semántica (*Hit Rate*) del 90,0%, validando formalmente el Requerimiento No Funcional de Rendimiento establecido.

La Tabla 14 presenta los resultados del motor de recuperación.

Tabla 14: Evaluación cuantitativa del motor de recuperación semántica.

Categoría del Documento	Hit Rate (Top-3)	MRR
Reglamentos Generales (Texto Largo)	96.5 %	0.89
Sílabos (Texto Mixto)	91.2 %	0.84
Mallas Curriculares (Tablas Complejas)	88.4 %	0.81
Promedio Global	92.0 %	0.84

Elaborado por: Estudiante

Fuente: Pruebas de validación del sistema

3.4.2 Uso de Recursos y Computación de Borde

La Tabla 15 evidencia el uso eficiente de hardware (VRAM), que logró un balance exitoso gracias a las migraciones técnicas recientes.

Tabla 15: Consumo de memoria en el servidor durante picos de inferencia.

Componente Arquitectónico Analizado	Consumo RAM (GB)	Consumo VRAM (GB)
Visión Computacional y Detección (WebSockets / OpenCV)	0.4	0.1
Base de Datos Vectorial de RAG (ChromaDB Local)	1.2	0.0
Inferencia de Lenguaje Natural (Modelo Qwen 2.5 Quantizado)	1.8	5.8
Servicios Periféricos (FastAPI, Gestión de Archivos, Frontend)	1.5	0.3
Total del Sistema Integrado	4.9 GB	6.2 GB

Elaborado por: Estudiante

Fuente: Monitoreo de recursos del servidor en producción

3.4.3 Estimado de Consumo Computacional

Se realizó un estimado de consumo computacional asociado a la inferencia generativa. Por cada sesión típica de un estudiante (aproximadamente 3 interacciones continuas de preguntas y respuestas), el sistema consume un promedio de 2500 tokens de contexto (entrada procesada por el RAG) y 800 tokens de generación (salida del LLM).

3.5 Cronograma y Presupuesto

Para la ejecución del proyecto, se elaboró un presupuesto estimado mensualizado (OPEX) y de inversión inicial (CAPEX) considerando los costos de las APIs utilizadas y la infraestructura del servidor local (Tabla 16).

Tabla 16: Presupuesto referencial de implementación y operación.

Categoría	Descripción	Costo (USD)
Hardware (CAPEX)	Servidor Local (i7, 32GB RAM, RTX 3060 12GB)	\$ 1,200.00
Infraestructura	Despliegue en DigitalOcean (Droplet básico - Opcional)	\$ 10.00 / mes
APIs de IA (OPEX)	Groq (Whisper-v3) y Eleven-Labs (TTS Streaming)	\$ 25.00 / mes
Mantenimiento	Soporte y actualización de mallas	\$ 50.00 / mes

Los valores presentados constituyen una estimación de referencia. Los costos asociados a APIs dependen del volumen real de uso, minutos de audio procesado, número de consultas y condiciones comerciales de los proveedores; por tanto, pueden variar durante una implementación institucional.

El desarrollo se planificó y ejecutó a lo largo de un periodo de cinco meses, estructurado según las iteraciones ágiles detalladas en la Tabla 17.

Tabla 17: Cronograma de ejecución del proyecto.

Fase / Mes	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5
Fase 1: Configuración Local e Indexación RAG	X				
Fase 2: Motor Cognitivo (LLM y Nemotron)		X	X		
Fase 3: Desarrollo Sensorial (STT y TTS)			X	X	
Fase 4: Integración Avatar 3D				X	
Fase 5: Pruebas de Latencia y Usabilidad					X

3.6 Evaluación de Usabilidad y Experiencia de Usuario

Para validar la efectividad de la solución, se aplicó una encuesta de usabilidad a una muestra de 13 estudiantes de la carrera de Tecnologías de la Información de diferentes semestres. La evaluación midió factores de integración, antropomorfismo, latencia percibida e intención de uso futuro. A continuación, se detallan los resultados gráficos de las preguntas clave.




Figura 14: Nivel de avance actual de los estudiantes encuestados.

El perfil de los usuarios indica que la mayoría se encuentra en el 4to y 8vo semestre, y presentan una alta frecuencia de uso previo de herramientas como ChatGPT o Claude, lo que evidencia familiaridad previa de la mayoría de los participantes con herramientas de IA generativa.

Respecto a la integración, la mayoría de los usuarios consideraron que la interfaz, el micrófono y el modelo 3D estaban de acuerdo o totalmente de acuerdo en estar bien integrados, demostrando una experiencia fluida.

En la claridad de la información, predominan valoraciones positivas, evidenciando que el motor RAG cumplió su objetivo de reducir

En los últimos 6 meses, ¿con qué frecuencia has interactuado con modelos de IA generativa (e.g., ChatGPT, Claude) para actividades académicas o de programación?

13 respuestas




Figura 15: Frecuencia de interacción previa con IA generativa.

¿Cuál es tu nivel de conocimiento técnico en renderización gráfica 3D o desarrollo de software interactivo?

13 respuestas




Figura 16: Conocimiento técnico en renderización 3D.




Figura 17: Percepción de integración de los módulos del sistema.




Figura 18: Claridad y precisión de la información académica.

Antropomorfismo (Apariencia del modelo 3D)
13 respuestas




Figura 19: Gestión de mensajes de error o fallos técnicos.

la fricción documental.

Animacidad (Fluidez de movimientos y sincronización labial)
13 respuestas




Figura 20: Comprensión precisa de las intenciones del usuario.

Afinidad visual y empatía
13 respuestas




Figura 21: Relevancia y utilidad de las respuestas de la IA.

Inteligencia percibida mediante su lenguaje corporal
13 respuestas




Figura 22: Capacidad de reconducción ante malentendidos.




Figura 23: Preferencia futura de uso del asistente virtual.

Finalmente, la mayoría de los participantes seleccionó las categorías 'De acuerdo' o 'Totalmente de acuerdo' respecto a su intención de utilizar nuevamente el asistente frente a la búsqueda web tradicional. Entre las sugerencias de mejora emitidas por los estudiantes se destacó optimizar aún más la latencia y ampliar la base de datos documental.

CAPÍTULO IV

CONCLUSIONES Y RECOMENDACIONES

4.1 Conclusiones

A partir del desarrollo e implementación del Asistente Virtual Inteligente, se han establecido las siguientes conclusiones respecto al cumplimiento de los objetivos planteados:

- El análisis de los procesos actuales permitió identificar limitaciones asociadas con la consulta manual de documentos y la ausencia de mecanismos de búsqueda semántica, lo cual permitió establecer los requerimientos funcionales y no funcionales del prototipo.
- Se diseñó una arquitectura modular cliente-servidor que integró el motor RAG, los servicios de voz, el módulo de interacción visual y el avatar 3D. El uso de WebSockets permitió implementar comunicación bidireccional y procesamiento asíncrono entre cliente y backend.
- Se implementó el motor RAG utilizando el modelo de embeddings `paraphrase-multilingual-MiniLM-L12-v2`, obteniendo un *Hit Rate* Top-3 global de 92,0% y un MRR de 0,84 en el conjunto de consultas empleado para la evaluación. Estos resultados evidencian un desempeño favorable del mecanismo de recuperación dentro de las condiciones evaluadas.
- La integración del avatar 3D, reconocimiento de voz, síntesis de voz y mecanismos de visión artificial permitió obtener un prototipo multimodal funcional. Las mediciones realizadas evidenciaron tiempos compatibles con una interacción conversacional en el entorno de prueba, aunque el rendimiento final depende de la infraestructura y de los servicios externos empleados.

- La evaluación piloto realizada con 13 estudiantes presentó una tendencia favorable en la percepción de integración, utilidad e intención futura de uso del prototipo. Debido al carácter exploratorio y al tamaño de la muestra, estos resultados se interpretan como evidencia inicial de aceptación y no como resultados generalizables a toda la población estudiantil.

4.2 Recomendaciones

Con base en los retos enfrentados y el análisis técnico del sistema en producción, se presentan las siguientes recomendaciones:

- **Escalabilidad y Pruebas de Estrés Exhaustivas:** Dado que las pruebas de concurrencia mediante JMeter tuvieron un alcance exploratorio para validar el funcionamiento asíncrono, se recomienda realizar pruebas de estrés a gran escala antes de un despliegue institucional definitivo. Esto permitirá dimensionar adecuadamente la infraestructura requerida e implementar estrategias de balanceo de carga en entornos en la nube (cloud) cuando el sistema migre desde el servidor local de desarrollo.
- **Dependencia de Red y Latencia (Limitación de APIs de Terceros):** Dado que los tiempos de respuesta de la transcripción y síntesis de voz dependen de servicios en la nube externos (ElevenLabs y Groq), el sistema es susceptible a variaciones en el ancho de banda institucional. Se recomienda explorar o implementar localmente modelos de voz (*On-Premise*) o sistemas de caché para mitigar retrasos si la conexión a internet de la universidad presenta intermitencias.
- **Calidad de la Base Documental (Limitación de Recuperación):** El motor RAG demostró mitigar efectivamente las alucinaciones siempre y cuando los documentos indexados sean de alta legibilidad semántica. Se recomienda que la administración del sistema aplique un protocolo estricto de curaduría de archivos PDF antes de cargarlos, rechazando documentos escaneados sin Reconocimiento Óptico de Caracteres (OCR) válido, ya que degradan la capacidad de búsqueda.

- **Control de costos operativos:** Debido a que los servicios externos de voz pueden incrementar su costo en función del volumen de solicitudes, se recomienda monitorear el consumo real durante una eventual implementación institucional y evaluar alternativas locales o esquemas de control de uso cuando sean necesarios.

4.3 Trabajos Futuros

El prototipo actual sienta una base tecnológica sólida sobre la cual pueden derivarse múltiples líneas de investigación o ampliación de producto:

- **Integración Profunda con el SGA Institucional:** Una evolución natural del proyecto consistiría en integrar la sesión autenticada del estudiante con las bases de datos transaccionales de la universidad (mediante APIs RESTful). Esto permitiría al asistente no solo informar sobre normas generales, sino brindar respuestas hiperpersonalizadas, tales como “Dada tu nota actual, te sugiero tomar estas dos materias como prerequisite”.
- **Generación de Emociones Dinámicas (Affective Computing):** Actualmente el avatar realiza sincronización labial y animaciones programadas. Como trabajo futuro, se puede entrenar un modelo de análisis de sentimientos que evalúe la carga emocional de la respuesta del LLM en tiempo real, activando *blendshapes* específicos (sonrisas ante buenas noticias o expresiones de empatía ante problemas) para dotar al avatar de inteligencia emocional.
- **Análisis Longitudinal del Impacto Estudiantil:** Ejecutar el protocolo de Google Forms diseñado a lo largo de uno o dos periodos académicos completos para analizar estadísticamente si la disponibilidad continua del asistente reduce el abandono estudiantil provocado por la desinformación de procesos administrativos.

REFERENCIAS

- [1] CENIA y CEPAL, "Índice latinoamericano de inteligencia artificial 2024-2025," Centro Nacional de Inteligencia Artificial (CENIA) / CEPAL, Tech. Rep., 2024.
- [2] WiseGuyReports, "Inteligencia artificial en el mercado de educación superior: Proyecciones y tendencias 2025-2035," WiseGuyReports, Tech. Rep., 2025.
- [3] UNESCO IESALC, "Configurando el futuro: El impacto de la educación superior en las políticas nacionales de IA," Instituto Internacional de la UNESCO para la Educación Superior en América Latina y el Caribe, Tech. Rep., 2024.
- [4] PUCE, "Aurel_ai y legalbot-ec: Modelos de inteligencia artificial locales y automatización en la educación superior," Pontificia Universidad Católica del Ecuador, Tech. Rep., 2024.
- [5] Universidad Tecnológica Indoamérica, "Informe de rendición de cuentas institucional y demografía estudiantil," Universidad Tecnológica Indoamérica (UTI), Tech. Rep., 2025.
- [6] UTI y CEDIA, "Modelamiento de procesos biológicos mediante el procesamiento de imágenes médicas con visión artificial e inteligencia artificial," *Boletín Científico Indoamérica*, vol. 12, no. 1, pp. 45-58, 2025.
- [7] M. Salazar and E. Morales, "Implementación de Unreal Engine 5 para mejorar el pensamiento crítico en los estudiantes de ingeniería en tecnologías de la información," Master's thesis, Universidad Tecnológica Indoamérica, 2024.
- [8] J. Carrasco and R. Vélez, "Implementación de la inteligencia artificial para el análisis de sentimientos de la percepción pública

mediante procesamiento de lenguaje natural,” Master’s thesis, Universidad Tecnológica Indoamérica, 2024.

- [9] S. A. Robinson, “Ai-based avatars are changing the way we learn and teach: benefits and challenges,” *Frontiers in Education*, vol. 9, 2024.
- [10] A. F. Pabón M., K. J. Barrios Q., S. D. Solano C., and C. G. Quintero M., “Naia: A robust artificial intelligence framework for multi-role virtual academic assistance,” *Systems*, vol. 13, no. 12, p. 1091, 2025.
- [11] Y. Wang and X. Chen, “Lightweight gaze control system for embodied conversational agents in public spaces,” *Electronics*, vol. 14, no. 8, p. 1592, 2024.
- [12] A. Abedi and S. S. Khan, “Engagement measurement based on facial landmarks and spatial-temporal graph convolutional networks,” *arXiv preprint arXiv:2403.17175*, 2024.
- [13] A. S. Cáceres Vega and C. P. Sarango Lapo, “Asistente virtual desplegado de manera holográfica,” Master’s thesis, Universidad Técnica Particular de Loja, 2024.
- [14] J. M. Guncay Carchipulla and W. R. Sinchi Morocho, “Desarrollo de un asistente virtual utilizando procesamiento de lenguaje natural y aprendizaje de máquina para comunicación con aspirantes a estudios de posgrado,” Master’s thesis, Universidad Politécnica Salesiana, 2022.
- [15] Pontificia Universidad Católica del Ecuador, “Integración de ia en la mesa de servicios tecnológicos de telefónica ecuador,” Master’s thesis, PUCE, 2024.
- [16] G. A. Díaz Pérez and J. R. Moreno Charco, “Asistente virtual basado en inteligencia artificial para la obtención de indicadores de desempeño,” 2025.
- [17] C. G. Quintero M. *et al.*, “Everydai: A virtual assistant for daily contextual decision-making,” *Systems*, vol. 13, no. 9, p. 753, 2025.

- [18] D. M. Laureano, D. L. Cruz-Romero, and C. Ovalle, "Asistente virtual basado en inteligencia artificial como herramienta de tesis para estudiantes universitarios de la carrera de ingeniería," in *20th LACCEI International Multi-Conference for Engineering, Education, and Technology*. LACCEI, 2022.
- [19] C. Fernández, M. A. Vicente, M. C. Carratalá, and S. Lorenzo, "Virtual 3d avatars as a training tool in university degrees," *International Journal of Advances in Electronics and Computer Science*, vol. 9, no. 12, 2022.
- [20] B. Kiran, "Talkmateai: A real-time, multimodal ai companion architecture," pp. 112–128, 2023.
- [21] B. A. Karagond, D. V. Shruthi, H. A. Bhat, H. M. Samarth, and D. Rahul, "Ai desktop assistant," *World Journal of Engineering Research and Technology*, vol. 10, no. 4, pp. 230–238, 2024.
- [22] L. Cárdenas, A. Pipino, M. T. Donadio, and P. Picota, "Modelo de un sistema de alerta basado en visión artificial para la prevención de aglomeraciones en el transporte público," *Visión Antataura*, vol. 8, no. 2, pp. 93–107, 2024.
- [23] A. R. Hevner, S. T. March, J. Park, and S. Ram, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004.

GLOSARIO

Definición de los términos técnicos y acrónimos relevantes utilizados a lo largo del documento:

API (Application Programming Interface): Interfaz que permite la comunicación entre diferentes componentes de software, utilizada en este proyecto para conectar servicios externos.

Burbujas Flotantes: Elementos de interfaz de usuario superpuestos dinámicamente sobre el canvas WebGL para presentar sugerencias de interacción de forma amigable.

Chunking: Proceso de dividir o fraccionar información. En este documento refiere al particionamiento de texto para indexación (RAG) o la transmisión de audio fragmentado (*Streaming*).

Cosine Similarity (Similitud Coseno): Métrica matemática utilizada para medir la semejanza entre dos vectores en un espacio multidimensional, fundamental para la recuperación de información.

Droplet: Servidor virtual privado escalable provisto por la infraestructura en la nube de DigitalOcean.

ECA (Embodied Conversational Agent): Agente conversacional que cuenta con una representación corporal visible, como un avatar 3D.

FastAPI: Marco de trabajo (*framework*) moderno y de alto rendimiento para construir APIs con Python.

GPU (Graphics Processing Unit): Unidad de procesamiento especializada, crucial para la aceleración de modelos de inteligencia artificial y el renderizado gráfico.

LLM (Large Language Model): Modelo de Inteligencia Artificial entrenado con cantidades masivas de texto capaz de comprender y generar lenguaje natural.

OCR (Optical Character Recognition): Tecnología utilizada para extraer texto desde imágenes o documentos escaneados.

PLN (Procesamiento de Lenguaje Natural): Rama de la inteligencia artificial enfocada en la interacción entre las computadoras y el lenguaje humano.

RAG (Retrieval-Augmented Generation): Arquitectura de IA que mejora las respuestas de un LLM al recuperar previamente información relevante de una base de datos de conocimiento específica.

Three.js: Biblioteca de JavaScript que facilita la creación y visualización de gráficos 3D en el navegador web mediante WebGL.

TTS (Text-to-Speech): Tecnología capaz de convertir texto escrito a audio sintetizado.

VRM (Virtual Reality Model): Formato de archivo estándar diseñado específicamente para la representación de avatares 3D interoperables en aplicaciones de realidad virtual o navegadores.

WebSockets: Protocolo de comunicación bidireccional, simultánea y en tiempo real a través de una única conexión TCP.

Whisper: Modelo de reconocimiento de voz y traducción (*Speech-to-Text*) de código abierto desarrollado por OpenAI.

ANEXO A

REPOSITORIO DE CÓDIGO Y CONFIGURACIONES TÉCNICAS

Este anexo detalla los enlaces a los repositorios donde se encuentra el código fuente del Asistente Virtual Inteligente, así como la configuración base de las variables de entorno para su correcto funcionamiento.

Repositorio de Código Fuente

- **Asistente Virtual (Código Fuente):** https://github.com/EmilioEJ/Asistente_Virtual
- **Documento de Tesis (LaTeX):** https://github.com/EmilioEJ/TFG_EmilioESPINOZA

Configuración Base (Archivo .env) A continuación se presenta un extracto de las variables de entorno necesarias para levantar el backend en FastAPI:

```
# Configuración del Servidor y CORS
PORT=8000
FRONTEND_URL=http://localhost:5173
```

```
# Modelos y APIs de IA
ELEVENLABS_API_KEY=tu_clave_aqui
ELEVENLABS_VOICE_ID=voz_valeria
GROQ_API_KEY=tu_clave_aqui
WHISPER_MODEL=whisper-large-v3
```

```
# Base de Datos Vectorial Local (ChromaDB)
CHROMA_DB_PATH=./chroma_db
EMBEDDING_MODEL=sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2
```

```
# Modelo LLM Local / API
```

NEMOTRON_ENDPOINT=http://localhost:11434/api/generate

ANEXO B

INSTRUMENTO DE EVALUACIÓN DE USABILIDAD

Para la evaluación del sistema, se utilizó un cuestionario basado en Google Forms distribuido a 13 estudiantes de la carrera. A continuación, se presenta la estructura de las preguntas formuladas:

■ Sección 1: Perfil Técnico del Evaluador

1. ¿Cuál es tu nivel de avance actual dentro de la carrera de TI?
2. En los últimos 6 meses, ¿con qué frecuencia has interactuado con modelos de IA generativa para actividades académicas? (Escala 1-5)
3. ¿Cuál es tu nivel de conocimiento técnico en renderización gráfica 3D o desarrollo interactivo? (Escala 1-5)

■ Sección 2: Usabilidad de la Interfaz y Arquitectura

4. Considero que las distintas funciones del sistema están bien integradas.
5. Encontré que el sistema es innecesariamente complejo de utilizar.
6. La información académica que provee el asistente es clara, precisa y fácil de entender.
7. El sistema muestra mensajes de error claros o me guía adecuadamente ante fallos.

■ Sección 3: Inteligencia Conversacional y NLP

8. Al inicio, el asistente explicó claramente su propósito y límites.
9. El asistente virtual comprendió mis intenciones y consultas técnicas con precisión.

10. Las respuestas de la IA fueron útiles y directamente relevantes.
11. Cuando la IA no entendió algo, fue capaz de reconducir la conversación amigablemente.

■ **Sección 4: Evaluación de la Interfaz del Avatar 3D**

12. Antropomorfismo. (1: Artificial - 5: Natural)
13. Animacidad. (1: Estático - 5: Vivo)
14. Afinidad visual y empatía. (1: Desagradable - 5: Agradable)
15. Inteligencia percibida. (1: Incompetente - 5: Competente)

■ **Sección 5: Visión Artificial y Aceptación Tecnológica**

16. Percibí una latencia aceptable entre la captura y la respuesta renderizada.
17. El uso de la cámara me pareció poco invasivo y confío en el manejo de privacidad.
18. Utilizar este asistente aumentaría mi eficiencia para encontrar información.
19. Basado en esta prueba, preferiría utilizar este asistente en el futuro.

■ **Sección 6: Diagnóstico Técnico**

20. ¿Qué mejora técnica priorizarías antes de lanzar este asistente a toda la universidad?

ANEXO C

FORMULARIO DE CONSENTIMIENTO INFORMADO

El siguiente formulario fue presentado a todos los participantes antes de la evaluación, indicando explícitamente el uso de la cámara web sin almacenamiento, asegurando la privacidad, el anonimato de los datos y el carácter voluntario de la prueba.

UNIVERSIDAD TECNOLÓGICA INDOAMÉRICA

Consentimiento Informado

Estudio de evaluación del asistente CampusBot - Trámite de homologación

Yo, _____, con cédula _____, declaro que participo de forma **voluntaria** en este estudio y doy mi consentimiento para que los datos que proporcione se utilicen de manera **anónima**, con fines exclusivamente de **investigación** y para la obtención de **resultados estadísticos**. Entiendo que mi participación es voluntaria y que mis datos no se usarán para ningún otro fin.

Firma

Fecha (día / mes / año)

Gracias por su participación. Universidad Tecnológica Indoamérica - Facultad de Ingeniería.

Figura 24: Formulario de consentimiento informado.

ANEXO D

APROBACIÓN DE ABSTRACT

A continuación se adjunta la evidencia de la aprobación del documento de resumen ejecutivo en su versión en inglés (Abstract).

UNIVERSIDAD TECNOLÓGICA INDOAMÉRICA

FACULTY OF ENGINEERING

Information Technology

AUTHOR: ESPINOZA JIMENEZ PAULO EMILIO

TUTOR: MSc. IZA LLUMIGUSIN CHRISTIAN EDUARDO

THEME

Development of an Intelligent Virtual Assistant Prototype with a 3D Avatar Interface and
Computer Vision for the Dissemination of Academic Information for Students in an Educational
Institution

ABSTRACT

This Curricular Integration Project addresses the limitations of current document repositories and institutional interfaces in disseminating academic information, which lack semantic search capabilities and proactive interactivity, leading to delays in routine student queries and administrative overload in administrative offices. Aiming to develop a prototype of an intelligent virtual assistant with a 3D avatar interface and computer vision for the dissemination of academic regulations and curricula, the Design Science Research Methodology (DSRM) was adopted in combination with the agile Scrum framework for iterative software development. The proposed hybrid architecture implements visual capture via bounding boxes and 3D graphic rendering using WebGL locally on the client device, while a local server orchestrates a Retrieval-Augmented Generation (RAG) engine utilizing the multilingual embedding model alongside the local Nemotron model. The main results demonstrate high semantic accuracy, achieving a Hit Rate of 92.0% in academic regulation retrieval, an average Time to First Byte (TTFB) response time of 450 ms ensuring conversational fluency via WebSockets, and a positive usability evaluation with 13 students regarding integration, accuracy, and usage preference. In conclusion, the decentralized architecture and the use of generative artificial intelligence provide a viable, robust solution that transforms traditional, static queries into an interactive, accessible, and efficient support channel for the university community.

KEYWORDS: Keywords: Generative artificial intelligence, Multimodal interactions, Virtual assistant, 3D rendering



Figura 25: Aprobación del Abstract.